

UNIVERSIDADE FEDERAL FLUMINENSE
INSTITUTO DE COMPUTAÇÃO
DEPARTAMENTO DE CIÊNCIA DA COMPUTAÇÃO

Lucca Sabbatini Reid Rodrigues

INVESTIGANDO O IMPACTO DAS TAREFAS DE EXTRAÇÃO E
NORMALIZAÇÃO DE AFIRMAÇÕES NA CLASSIFICAÇÃO DE FATOS EM
PORTUGUÊS COM TRANSFORMERS

Trabalho de Conclusão de Curso submetido ao Departamento de Ciência da Computação da Universidade Federal Fluminense como requisito parcial para a obtenção do título de Bacharel em Ciência da Computação.

Niterói
2025

Lucca Sabbatini Reid Rodrigues

INVESTIGANDO O IMPACTO DAS TAREFAS DE EXTRAÇÃO E
NORMALIZAÇÃO DE AFIRMAÇÕES NA CLASSIFICAÇÃO DE FATOS EM
PORTUGUÊS COM TRANSFORMERS

Trabalho de Conclusão de Curso submetido ao Departamento de Ciência da Computação da Universidade Federal Fluminense como requisito parcial para a obtenção do título de Bacharel em Ciência da Computação.

Aprovado em 08 de Dezembro de 2025:

Profa. Aline Marins Paes Carvalho
Orientadora - UFF

Vítor Nascimento Lourenço
Coorientador - UFF

Prof. Leandro Santiago de Araújo
UFF

Prof. Paulo Roberto Mann Marques
Júnior
UFRJ

Niterói
2025

Ficha catalográfica automática - SDC/BEE
Gerada com informações fornecidas pelo autor

R696i Rodrigues, Lucca Sabbatini Reid
Investigando o impacto das tarefas de extração e
normalização de afirmações na classificação de fatos em
português com Transformers / Lucca Sabbatini Reid Rodrigues. -
2025.
68 f.: il.

Orientador: Aline Marins Paes Carvalho.
Coorientador: Vítor Nascimento Lourenço.
Trabalho de Conclusão de Curso (graduação)-Universidade
Federal Fluminense, Instituto de Computação, Niterói, 2025.

1. Desinformação. 2. Checagem de fatos. 3. Inteligência
artificial. 4. Extração e normalização de afirmações. 5.
Produção intelectual. I. Carvalho, Aline Marins Paes,
orientadora. II. Lourenço, Vítor Nascimento, coorientador.
III. Universidade Federal Fluminense. Instituto de
Computação. IV. Título.

CDD - XXX

Investigando o Impacto das Tarefas de Extração e
Normalização de Afirmções na Classificação de Fatos em
Português com *Transformers*
*Investigating the Impact of the Claim Extraction and
Claim Normalization Tasks on the Classification of Facts
in Portuguese with Transformers*

Lucca Sabbatini Reid Rodrigues ¹

Vítor Nascimento Lourenço²

Aline Marins Paes Carvalho³

Resumo

Fake news (ou notícias falsas) são ameaças perigosas à sociedade contemporânea, e são propagadas de maneira acelerada por meio da *internet*, e principalmente das redes sociais. Paralelamente, os avanços dos modelos de Inteligência Artificial (IA) generativa tornam cada vez mais difícil discernir conteúdos verdadeiros de conteúdos fabricados. Contudo, os modelos de IA também podem atuar como ferramentas promissoras no combate à desinformação. Este estudo explora o impacto das tarefas de *Claim Extraction* (extração de afirmações) e *Claim Normalization* (normalização de afirmações) na classificação de notícias falsas em português. O objetivo é analisar o impacto na classificação de notícias e publicações em redes sociais em português como verdadeiras ou falsas após a transformação dos textos originais pelas tarefas de extração e normalização. Para tanto, empregam-se modelos de linguagem como GPT-5 nano e GPT-5 para a transformação de conjuntos de dados, e modelos *Transformer* como o XLM-RoBERTa-Large e o BERTimbau são ajustados para a classificação destes conjuntos de dados. O estudo conclui que existe um balanço a ser atingido na utilização destas tarefas para classificação de notícias falsas, pois, assim como elas são capazes de organizar as ideias de uma publicação em rede social sem estrutura, elas também podem eliminar contexto relevante para a classificação.

Palavras-chaves: desinformação; checagem de fatos; extração de afirmações; normalização de afirmações; LLMs; Transformers.

¹ Graduando do Curso de Ciência da Computação - UFF, luccasabbatini@id.uff.br

² Coorientador - Instituto de Computação - UFF, vitorlourenco@id.uff.br

³ Orientadora - Instituto de Computação - UFF, alinepaes@ic.uff.br

Abstract

Fake news is a dangerous threat to contemporary society, and are rapidly spread through the *internet*, especially on social media. At the same time, advances in generative Artificial Intelligence (AI) models make it increasingly difficult to distinguish real content from fabricated content. However, AI models can also serve as promising tools in the fight against misinformation. This study explores the impact of *Claim Extraction* and *Claim Normalization* tasks on fact-checking in Portuguese. The objective is to analyze the classification of news articles and social media posts in Portuguese as true or false after the transformation of the original texts through extraction and normalization tasks. To this end, language models such as GPT-5 nano and GPT-5 are employed for dataset transformation, and *Transformer* models such as XLM-RoBERTa-Large and BERTimbau are fine-tuned for the classification of these datasets. The study concludes that there is a balance to be achieved in the use of these tasks for fact-checking, while they are capable of organizing the ideas in an unstructured social media post, they may also remove relevant context needed for classification.

Keywords: misinformation; fact-checking; claim extraction; claim normalization; LLMs; Transformers.

Aprovado em: 08/12/2025. **Versão Final em:** 14/12/2025

1. INTRODUÇÃO

O termo “*fake news*”, ou notícias falsas, passou a ser muito utilizado após o impacto da disseminação de notícias falsas nas eleições presidenciais estadunidenses no ano de 2016, e esse termo pode ser definido como artigos de notícias que são intencionalmente e verificavelmente falsos, e podem induzir os leitores ao erro (ALLCOTT; GENTZKOW, 2017). A pesquisa de Allcott também aponta o papel que as redes sociais exercem na disseminação de notícias falsas, atuando como canais de distribuição altamente eficazes e com características estruturais que as tornam especialmente propícias para esse tipo de conteúdo. Algumas dessas características são o baixo custo para produzir e propagar conteúdos, o grande alcance individual e a ausência de um julgamento editorial que, embora tenha melhorado com as iniciativas de identificação de notícias falsas e desinformação, como o mecanismo de checagem de fatos do Facebook (META, 2025) baseado na colaboração de verificadores de fatos independentes certificados pela *International Fact-Checking Network* (POYNTER, 2025), ainda não são suficientes para erradicar o problema.

As *fake news* também podem ser definidas como informações fabricadas que imitam o produto da mídia jornalística na forma, mas não no processo organizacional ou na intenção (LAZER *et al.*, 2018). São consideradas uma subcategoria de desinformação, que por sua vez é definida como qualquer informação incorreta ou enganosa sobre acontecimentos no mundo (LAZER *et al.*, 2018). O impacto das *fake news* é considerado um problema global e prejudicial devido à sua capacidade de minar a credibilidade da mídia padrão, reforçar e criar narrativas não verdadeiras e moldar a opinião das pessoas se baseando em informações falsas (LAZER *et al.*, 2018).

A desinformação e as notícias falsas não são conceitos novos. Na verdade, a ideia de fabricar uma informação propositalmente incorreta a fim de manipular o pensamento de indivíduos é bem antiga, e existe pelo menos desde a época do império romano com a campanha de propaganda que Otávio conduziu contra Marco Antônio por volta de 44 a.C., concebida para manchar a sua reputação, retratando-o como um mulherengo e um bêbado, e insinuando que ele se tinha tornado um fantoche de Cleópatra (POSETTI; MATTHEWS, 2018). Dito isso, as notícias falsas, ainda são tema de debate na sociedade atual por terem um poder de impacto devastador na sociedade contemporânea, como, por exemplo, a disseminação de propaganda antisemita por parte do partido nazista baseada em desinformação que culminou no holocausto (POSETTI; MATTHEWS, 2018).

Um dos motivos das *fake news* serem consideradas ainda mais perigosas hoje é sua rápida e fácil propagação por meio das redes sociais por conta da distribuição *peer-to-peer* (POSETTI; MATTHEWS, 2018) e por serem ambientes projetados para propagar conteúdos para milhões de pessoas todo o dia por definição. Além

disso, também são ambientes nos quais as regulações que visam controlar diversos aspectos, incluindo a disseminação de informação falsa, estão em processo de amadurecimento. Este perigo das redes sociais como veículo de propagação de *fake news* pode ser observado mediante a análise dos acontecimentos e polêmicas envolvendo notícias falsas nas redes sociais que acompanharam as eleições presidenciais estadunidenses de 2016 (ALLCOTT; GENTZKOW, 2017) e as eleições presidenciais brasileiras de 2018 (DOURADO, 2020). Contudo, estes acontecimentos também serviram como motivação para a utilização de ferramentas como o portal Aos Fatos (FATOS, 2025) para combater e mitigar os efeitos catastróficos da utilização de desinformação para manipulação de pensamentos e criação de narrativas.

O papel da inteligência artificial neste debate é relativo e depende muito do seu uso, pois, assim como portais de checagem de fatos, pode tanto ser usada para combater a desinformação como para gerá-la e propagá-la. O intuito deste estudo é explorar a eficácia das tarefas de extração e normalização de afirmações oriundas de publicações de redes sociais no combate às notícias falsas com o uso de inteligência artificial, uma vez que estas tarefas atacam alguns dos problemas centrais na classificação de fatos: textos extensos, com falta de uma estrutura textual bem definida e que se utilizam de gírias e linguagem informal dificultam a identificação e classificação de notícias falsas em publicações em redes sociais.

1.1. MOTIVAÇÃO

Como aponta a introdução, publicações de notícias falsas podem ser extensas, desorganizadas e ambíguas, além de às vezes conter informações desnecessárias no escopo do assunto discutido. Por conta disso, é importante identificar, as declarações verificáveis que realmente devem ser analisadas (extração) e reformular essas declarações em versões mais claras, completas e livres de redundâncias ou ruídos linguísticos (normalização).

Inclusive, a relevância e a importância de tais tarefas também foram demonstradas na Tarefa 2 (CLEF, 2025b) do *CheckThat! Lab 2025* (CLEF, 2025a), que foi uma competição científica de pesquisa em processamento de linguagem natural em subjetividade, checagem de fatos, extração e normalização de afirmações e recuperação, associado à edição de 2025 do evento *Conference and Labs of the Evaluation Forum* (CLEF, 2025c), que por sua vez é um conjunto de laboratórios e *workshops* dedicados à avaliação de sistemas de acesso à informação e ao teste de novas formas de avaliação. A tarefa foi definida pela conferência por meio do enunciado abaixo extraído e traduzido da seguinte URL:

<https://checkthat.gitlab.io/clef2025/task2/>

Dada uma postagem ruidosa e não estruturada de mídia social, a tarefa é simplificá-la em uma forma concisa. Portanto, buscamos reduzir essa lacuna decompondo postagens de mídia social em formas mais simples e compreensíveis, que são chamadas de afirmações normalizadas. (CLEF, 2025b).

Embora a proposta de pesquisa da conferência envolva múltiplas línguas, inclusive o português, a pesquisa que serviu de base para a formulação da tarefa, assim como a maioria das ferramentas existentes para checagem de fatos, foi desenvolvida em inglês. O ecossistema brasileiro é gravemente afetado pela propagação de desinformação nas redes sociais (DOURADO, 2020), e a ausência de métodos robustos adaptados ao português limita a eficácia dos sistemas de verificação automática. Características linguísticas próprias do português, como por exemplo a flexão rica, a variação morfológica, a pronominalização e a ambiguidade sintática, trazem desafios para a tarefa na língua portuguesa, que se tornam ainda maiores no português utilizado nas redes sociais.

Outra questão é a maneira como as tarefas de extração e normalização de afirmações serão aplicadas. Uma possibilidade de lidar com essas tarefas é com o uso de modelos baseados na arquitetura *Transformer*, uma abordagem explorada pelos artigos citados na Seção 3. Porém, ter dados anotados para esse tipo de tarefa também não é trivial, agravado no caso do português. Com isso, usar LLMs (*Large Language Models*, ou Modelos de Linguagem de Larga Escala) para a realização destas tarefas é uma alternativa. A motivação desta pesquisa é estudar a aplicação e analisar os resultados das tarefas de extração e normalização de afirmações em publicações de redes sociais através do uso de LLMs para fortalecer checagem de fatos em português.

1.2. DEFINIÇÃO DAS TAREFAS DE EXTRAÇÃO E NORMALIZAÇÃO DE AFIRMAÇÕES

O artigo “*From Chaos to Clarity: Claim Normalization to Empower Fact-Checking*” (SUNDRIYAL; CHAKRABORTY; NAKOV, 2024) foi usado como base para a elaboração da Tarefa 2 do *CheckThat! Lab 2025*, e as definições a seguir das tarefas de extração e normalização de afirmações adotadas por esta pesquisa também se baseiam nele.

1.2.1. Extração de afirmações

A tarefa de extração de afirmações (*Claim Extraction*) consiste no processo de identificação e localização das afirmações ou alegações principais feitas por um texto. Não envolve necessariamente reescrita da afirmação. Muitas das vezes, o resultado de uma tarefa de extração de afirmações é um trecho, um fragmento do texto inteiro analisado sem modificação ou com modificações mínimas. É útil em

contextos em que as entradas possuem e respeitam uma estrutura bem definida de escrita. Exemplos de extração de afirmações podem ser encontrados na Tabela 1.

Publicação em Rede Social	Afirmação Extraída
OLHA a MERDA que a Globo irá promover!!!! - Cantor que chamou Jesus de travesti se apresentará no Criança Esperança https://noticias.gospelprime.com.br/johnny-hooker-jesus-travesti-crianca-esperanca/ ...	Cantor que chamou Jesus de travesti se apresentará no Criança Esperança
Até quando vamos ser obrigados ver esses terroristas desfilando pelo nosso país. Não respeitam nada. MST invadindo Brumadinho. #BrasilÉBolsonaro #MoroTePrendeuBabaca pic.twitter.com/Vg6hn9WZXX	MST invadindo Brumadinho
dicas de saúde: conheça o aranto , que é a planta que cura cancer	conheça o aranto , que é a planta que cura cancer

Tabela 1 – Exemplos de publicações e suas afirmações extraídas retirados dos conjuntos de dados original e transformados baseados na base FakeTweet.Br (CORDEIRO; PINHEIRO, 2019).

1.2.2. Normalização de afirmações

A tarefa de normalização de afirmações (*Claim Normalization*) consiste na extração e simplificação da afirmação central de um texto, com o intuito de se livrar do ruído presente em volta das informações. O resultado geralmente é uma afirmação concisa, direta ao ponto, verificável e autocontida. É útil em contextos em que os textos não possuem estrutura definida e possuem ruídos, como é o caso de publicações em redes sociais. Exemplos de normalização de afirmações podem ser encontrados na Tabela 2.

1.3. OBJETIVOS

Dado o contexto de checagem de fatos em português sem recuperação de evidências e com base nas seções de introdução e motivação acima, a pesquisa visa responder às seguintes perguntas:

QP1: A tarefa de extração de afirmações melhora a classificação de notícias e publicações de redes sociais como verdadeiras ou falsas?

QP2: A tarefa de normalização de afirmações melhora a classificação de notícias e publicações de redes sociais como verdadeiras ou falsas?

Publicação em Rede Social	Afirmação Normalizada
<i>Research into the dangers of cooking with aluminum foil has found that some of the toxic metal can contaminate food. Increased levels of aluminum in the body have been linked to osteoporosis, and Alzheimer's disease.</i>	<i>Cooking in Aluminum foil causes Alzheimer's Disease.</i>
<i>Did you know when ur child turns 6. U can add them as authorized user to one of ur credit cards. Never give them card, & all payments u make from 6 to 18 goes to ur child credit too..ur kid will have a unbelievable credit score from years of payment history.</i>	<i>6-year-old kids can be added as authorized users on all credit cards.</i>
<i>As if it couldn't get any worse. #Hope4Cancer says #RootCanal causes #CANCER Solution... Rip Cancer patients teeth out. Monsters #FalseHope4Cancer #ProtectCancerPatients</i>	<i>Root canal treatment causes cancer</i>

Tabela 2 – Exemplos de publicações e suas afirmações normalizadas retirados do artigo “*From Chaos to Clarity: Claim Normalization to Empower Fact-Checking*” (SUNDRIYAL; CHAKRABORTY; NAKOV, 2024).

1.4. CONTRIBUIÇÕES

Este trabalho tem como principal contribuição os resultados da análise empírica do impacto das tarefas de extração e normalização de afirmações no desempenho de modelos *Transformer* na tarefa de classificação de fatos em português. O estudo aborda diretamente os desafios impostos pelas características linguísticas próprias do português, especialmente no contexto da linguagem informal das redes sociais, e conclui que a tarefa de normalização de afirmações gera resultados geralmente melhores do que a extração. Além disso, a normalização realizada com modelos que não possuem tanta capacidade de raciocínio também traz resultados relevantes e positivos.

1.5. ORGANIZAÇÃO DO TEXTO

A organização deste trabalho está dividida nas seguintes seções: a Seção 2, denominada Referencial Teórico, dedica-se a expor e esclarecer de maneira sucinta e objetiva os conceitos teóricos explorados e utilizados ao longo da pesquisa, incluindo Inteligência Artificial, Aprendizado de Máquina, Aprendizado Profundo, Redes Neurais, Transformers e LLMs; a Seção 3, Trabalhos Relacionados, cita e correlaciona artigos que serviram de base para o desenvolvimento do estudo, focando em pesquisas sobre a extração e normalização de afirmações e a checagem de fatos com Transformers; a Seção 4, Metodologia, é responsável por definir e descrever o expe-

rimento elaborado para buscar as respostas das questões de pesquisa, detalhando a arquitetura, a escolha dos conjuntos de dados, dos LLMs para realização das tarefas de extração e normalização e dos modelos *Transformer* utilizados na classificação, além de descrever os *prompts* e o formato de execução; a Seção 5, Análise de Resultados, apresenta e investiga os resultados obtidos na execução do experimento para buscar as respostas das questões de pesquisa do trabalho. Inclui a análise das informações das entradas, dos exemplos transformados, das métricas dos modelos e dos casos de melhora ou piora na classificação; por fim, a Seção 6, Conclusão, resume as descobertas da pesquisa, aborda as ameaças à validade que podem ter influenciado os resultados e sugere ideias para trabalhos futuros.

Este trabalho conta também com os Apêndices A - Lista de ilustrações, B - Lista de tabelas, C - Bibliotecas Python utilizadas na construção dos Jupyter Notebooks do experimento, D - Configurações dos LLMs e das tarefas no componente responsável pela transformação de conjuntos de dados, E - Configurações dos ajustes-finos dos *Transformers* e F - Resultados dos ajustes-finos dos *Transformers*.

2. REFERENCIAL TEÓRICO

O objetivo desta seção é expor e esclarecer de maneira sucinta e objetiva os conceitos teóricos explorados e utilizados ao longo da pesquisa.

2.1. INTELIGÊNCIA ARTIFICIAL, APRENDIZADO DE MÁQUINA E APRENDIZADO PROFUNDO

Os conceitos de inteligência artificial, aprendizado de máquina e aprendizado profundo serão brevemente discutidos abaixo com base em artigos relevantes para os temas e principalmente no livro *Understanding Deep Learning* (PRINCE, 2023), que serviu de base para o estudo de como construir e realizar os experimentos desenvolvidos neste artigo.

2.1.1. Inteligência artificial

De acordo com Prince (PRINCE, 2023), a inteligência artificial pode ser definida da seguinte maneira:

Inteligência artificial, ou IA, está relacionada à construção de sistemas que simulam comportamento inteligente. Ela abrange uma ampla variedade de abordagens, incluindo aquelas baseadas em lógica, busca e raciocínio probabilístico (PRINCE, 2023).

Uma outra definição de inteligência artificial é:

[...] a ciência e engenharia de fazer máquinas inteligentes, especialmente programas de computador inteligentes. Está relacionada à tarefa similar de usar computadores para entender a inteligência humana [...] (MC-CARTHY *et al.*, 2007).

Combinando estas duas definições, é possível entender a inteligência artificial como uma área da ciência da computação dedicada ao desenvolvimento de sistemas capazes de executar tarefas que exigem inteligência humana de forma autônoma.

2.1.2. Aprendizado de máquina

De acordo com Prince (PRINCE, 2023), o aprendizado de máquina (*machine learning*) é definido como um subconjunto da inteligência artificial. É a área que se dedica a construir sistemas que aprendem a tomar decisões ajustando modelos matemáticos a dados observados.

O processo de ajustar ou treinar um modelo envolve encontrar os parâmetros que definem a relação particular entre as entradas e as saídas de um problema. O modelo representa uma família de possíveis equações que mapeiam as entradas para as saídas, e o treinamento busca a equação que descreve os dados de treinamento com maior precisão.

Por fim, o aprendizado de máquina pode ser dividido em três grandes áreas:

- **Aprendizado supervisionado:** consiste no treinamento de um modelo que utiliza um conjunto de dados com pares de entrada e saída conhecidos, visando definir um mapeamento de dados de entrada para uma previsão de saída;
- **Aprendizado não supervisionado:** consiste no treinamento de um modelo que utiliza um conjunto de dados com entradas sem rótulos de saída correspondentes, o que significa que não há "supervisão". O objetivo principal não é mapear a entrada para a saída, mas sim descrever ou entender a estrutura dos próprios dados;
- **Aprendizado por reforço:** consiste na estratégia de treinamento para modelos que precisam tomar decisões de maneira sequencial. Estes modelos executam ações em um ambiente para maximizar as recompensas recebidas ao longo do tempo.

2.1.3. Redes neurais

De acordo com Prince (PRINCE, 2023), uma rede neural é definida como uma função matemática com um conjunto de parâmetros que mapeia entradas multidimensionais para saídas multidimensionais por meio de uma arquitetura específica composta por três partes principais: camada de entrada; camada(s) oculta(s); e

camada de saída. As conexões entre essas camadas são chamadas de pesos, que são responsáveis por multiplicar a saída de uma camada e adicionar o resultado à camada seguinte.




Figura 1 – Exemplo de uma rede neural simples retirado do livro *Understanding Deep Learning* (PRINCE, 2023), no qual: o nó x representa a entrada do modelo; os nós h_1 , h_2 e h_3 correspondem aos neurônios da camada oculta, responsáveis por transformar a entrada por meio de combinações lineares e funções de ativação; o nó y representa a saída da rede, que agrega as informações provenientes da camada oculta; e as setas indicam as conexões direcionadas entre os neurônios, associadas aos pesos aprendidos durante o treinamento, definindo o fluxo de informação da entrada para a saída.

A computação em uma rede neural começa com o cálculo de uma combinação linear, definida pelo somatório das entradas ponderado pelos pesos e acrescido de um viés. Em seguida, os resultados dessa combinação linear são servidos como entrada para uma função de ativação, responsável por introduzir não linearidade ao modelo, o que aumenta a capacidade de representação do modelo e possibilita o aprendizado de relações complexas. Com isso, as funções de ativação produzirão saídas que, por sua vez, vão servir de entrada para a próxima camada. O modelo continua fazendo transformações lineares e ativações até chegar na última camada e formar as saídas da rede neural propriamente dita.

Por fim, as redes neurais podem ser classificadas em:

- **Rasas:** definidas como as redes neurais que possuem apenas uma camada oculta.
- **Profundas:** definidas como as redes neurais que possuem múltiplas camadas ocultas. São uma extensão das redes rasas.

2.1.4. Aprendizado profundo

De acordo com Prince (PRINCE, 2023), o aprendizado profundo (*deep learning*) é o processo de usar um conjunto de dados para treinar redes neurais profundas para que se tornem capazes de reconhecer padrões, fazer previsões e tomar decisões.

Em outras palavras, ele é uma subárea do aprendizado de máquina na qual o modelo matemático treinado é uma rede neural profunda.

O treinamento de um modelo de aprendizado profundo é o processo de ajustar os pesos de uma rede neural profunda para que ela mapeie as entradas do conjunto de dados de treinamento para as saídas desejadas com a maior precisão possível.

Este processo envolve três conceitos principais:

- **A função de perda:** função que retorna valores escalares que resumem o quão mal o modelo prediz as saídas de treinamento para um dado conjunto de pesos. O objetivo do treinamento é encontrar os valores ótimos para os pesos que minimizam essa função de perda. Um valor de perda menor significa um modelo melhor;
- **O cálculo do gradiente:** consiste em determinar a direção de maior crescimento da função de perda. Assim, para reduzir a perda, o modelo atualiza os pesos na direção oposta ao gradiente. O gradiente é obtido derivando-se a função de perda em relação aos pesos do modelo, normalmente por meio do método de *backpropagation*;
- **O algoritmo de otimização:** após o cálculo do gradiente, o próximo passo é atualizar os pesos da rede a fim de minimizar a função de perda. Utiliza-se para isso um algoritmo de otimização iterativo. O método padrão para treinar redes neurais é a Descida de Gradiente Estocástico (SGD), no qual os pesos são ajustados movendo-se uma pequena distância (denominada de taxa de aprendizado) na direção que diminui o valor da função de perda (direção oposta à do gradiente). Embora o método clássico SGD, com atualizações proporcionais à taxa de aprendizado e realizadas na direção oposta ao gradiente, seja simples e eficiente em muitos cenários, diversos otimizadores modernos como Adam (KINGMA; BA, 2017), RMSProp (HINTON, 2012) e AdaGrad (DUCHI; HAZAN; SINGER, 2011) introduzem adaptações como momentos, normalizações ou ajustes por parâmetro que podem acelerar ou estabilizar o treinamento.

Além disso, existem diversos outros aspectos do treinamento de uma rede profunda que visam obter modelos melhores e de maneira mais eficiente, como regularização e normalização de pesos, aperfeiçoamentos dos algoritmos de otimização e técnicas melhores para cálculo de gradientes.

Ao final do treinamento de um modelo, é possível avaliar seu desempenho na execução de uma tarefa com o cálculo de métricas. As métricas mais comuns para tarefas de classificação e usadas como base para avaliar o desempenho dos modelos neste experimento são:

- **Accuracy (acurácia):** proporção de previsões corretas entre todas as previsões feitas;

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precision (precisão):** proporção dos exemplos classificados como positivos que realmente são positivos;

$$Precision = \frac{TP}{TP + FP}$$

- **Recall:** proporção dos exemplos realmente positivos que o modelo conseguiu identificar como positivos;

$$Recall = \frac{TP}{TP + FN}$$

- **F1:** média harmônica entre precisão e *recall*, equilibrando ambos em uma única métrica.

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Onde: $TP \rightarrow$ verdadeiros positivos; $TN \rightarrow$ verdadeiros negativos; $FP \rightarrow$ falsos positivos; $FN \rightarrow$ falsos negativos;

2.2. TRANSFORMERS E LLMS

O termo *Transformer* se refere a uma arquitetura para redes neurais profundas baseada fortemente em mecanismos de atenção (VASWANI *et al.*, 2017), diminuindo o uso de redes neurais recorrentes que comandavam o âmbito do processamento natural de linguagem, principalmente com as arquiteturas LSTM (HOCHREITER; SCHMIDHUBER, 1997) antes de seu surgimento. Arquiteturas baseadas em *Transformers* são as principais usadas para processamento de linguagem natural e geração de texto.

Seguem a arquitetura geral de *encoder-decoder* (codificador-decodificador), na qual:

- **Encoder:** é responsável por ler a entrada e transformá-la em uma representação em um espaço vetorial, ou *embedding*;
- **Decoder:** é responsável por consumir os *embeddings* e gerar a saída um passo de cada vez.

A arquitetura *Transformer* é revolucionária por acabar com os problemas presentes nas redes neurais recorrentes relacionados à paralelização e velocidade de treinamento, dificuldade de capturar relações entre elementos distantes nas entradas, desaparecimento e explosão de gradientes e muitos outros. Os mecanismos

de atenção dos *Transformers* são capazes não só de capturar dependências entre elementos distantes em entradas com facilidade, mas também possibilitam o treinamento em paralelo, uma vez que o mecanismo de *self-attention* da arquitetura processa toda a sequência de entrada de uma só vez (VASWANI *et al.*, 2017).

O termo LLM se refere a *Large Language Model*, ou seja, modelos grandes de linguagem, e são baseados na arquitetura do *decoder* de um *Transformer*, uma vez que sua finalidade é geração de texto. São modelos com muitos parâmetros e treinados em quantidades muito grandes de texto, e que, por conta dessa grande escala, desenvolvem habilidades emergentes. Conforme o livro “Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português” (CASELI; NUNES, 2024), estas habilidades emergentes são capacidades de realizar tarefas que os modelos não foram inicialmente treinados para resolver, mas que conseguem resolver sem treinamento posterior. São tarefas relacionadas ao processamento de linguagem natural e geração de texto que não costumam ser observadas em modelos menores.

3. TRABALHOS RELACIONADOS

Como visto na Seção 1.1, a fonte de informação principal desta pesquisa foi uma tarefa proposta pela *Task 2* do *CheckThat! Lab no CLEF 2025*.

O artigo “*From Chaos to Clarity: Claim Normalization to Empower Fact-Checking*” (SUNDRIYAL; CHAKRABORTY; NAKOV, 2024) é citado pela tarefa como referência e contempla um estudo sobre a normalização de tarefas que a conferência propõe para desenvolvimento.

Dentre os artigos submetidos como soluções para a tarefa proposta pelo evento, dois artigos foram destacados e selecionados como fonte de estudo para a realização desta pesquisa. São eles os artigos “*dfkinit2b at CheckThat! 2025: Leveraging LLMs and Ensemble of Methods for Multilingual Claim Normalization*” (ANIKINA *et al.*,) e “*AKCIT-FN at CheckThat! 2025: Switching Fine-Tuned SLMs and LLM Prompting for Multilingual Claim Normalization*” (ALMADA *et al.*, 2025).

Além do escopo das tarefas de extração e normalização de afirmações, o artigo “*Surprising Efficacy of Fine-Tuned Transformers for Fact-Checking over Larger Language Models*” (SETTY, 2024) também serviu como base para o desenvolvimento desta pesquisa pelo estudo feito e resultados obtidos sobre o ajuste-fino de *Transformers* para a tarefa de checagem de fatos.

Esta seção visa citar e correlacionar estes artigos utilizados como bases para o estudo e elaboração dos experimentos desta pesquisa.

3.1. EXTRAÇÃO E NORMALIZAÇÃO DE AFIRMAÇÕES

O artigo “*From Chaos to Clarity: Claim Normalization to Empower Fact-Checking*” (SUNDRIYAL; CHAKRABORTY; NAKOV, 2024) busca introduzir uma nova tarefa chamada *Claim Normalization*, ou normalização de afirmações, a fim de melhorar a eficiência de trabalhos de verificação de fatos. O trabalho busca preencher a lacuna apresentada pelo ruído inerente às postagens de mídia social, que torna árdua e demorada a extração de alegações precisas e proeminentes que exigem verificação. Para resolver esse problema, a tarefa de normalização de afirmações visa decompor postagens complexas e ruidosas de mídias sociais em formas mais diretas e compreensíveis, referidas como *Normalized Claims* (afirmações normalizadas). Em suma, busca extrair e simplificar a afirmação central feita em uma postagem longa e ruidosa de mídia social. Este artigo é responsável por desenvolver esta ideia de extração e normalização de afirmações e desenvolver uma abordagem para extrair e normalizar afirmações de publicações de redes sociais de maneira que a verificação destas afirmações seja mais eficiente e correta, que é o ponto principal da pesquisa deste artigo.

O artigo “*dfkinit2b at CheckThat! 2025: Leveraging LLMs and Ensemble of Methods for Multilingual Claim Normalization*” foi submetido como resolução da tarefa da conferência, e os resultados obtidos foram altamente competitivos, destacando-se tanto no cenário de avaliação monolíngue quanto no cenário *zero-shot*. No cenário monolíngue, a equipe alcançou o primeiro lugar em 6 das 13 línguas e ficou em segundo ou terceiro lugar nas línguas restantes. No cenário *zero-shot*, a equipe obteve o desempenho mais alto em todas as sete línguas não vistas, demonstrando forte capacidade de generalização para línguas para as quais não havia dados de treino disponíveis. Dentro das abordagens adotadas pelo trabalho, a abordagem de *prompting* alcançou os melhores resultados em três línguas no cenário monolíngue. Além disso, a tradução do *prompt* original em inglês para a língua-alvo foi também responsável pela qualidade dos resultados.

O artigo “*AKCIT-FN at CheckThat! 2025: Switching Fine-Tuned SLMs and LLM Prompting for Multilingual Claim Normalization*” também se destacou dentre as submissões da tarefa, uma vez que seus resultados obtidos também foram expressivos. A abordagem da equipe alcançou posições de pódio em quinze das vinte línguas avaliadas. Para o português, língua inicial de desenvolvimento da equipe, o sistema alcançou o terceiro lugar com uma pontuação média *METEOR* de 0.5290. A melhor submissão para português utilizou o ajuste-fino do modelo Mono PTT5 base (PIAU; LOTUFO; NOGUEIRA, 2024). Além disso, assim como no artigo anterior, o cenário *zero-shot* com LLMs demonstrou fortes capacidades de generalização.

Diante destes resultados, os *prompts*, técnicas e ideias desenvolvidos pelas equipes citadas acima serviram de inspiração para o desenvolvimento dos *prompts*

para execução das tarefas de extração e normalização de afirmações no experimento deste artigo. Os *prompts* dos experimentos deste artigo podem ser encontrados na Seção 4.5.

3.2. CHECAGEM DE FATOS COM *TRANSFORMERS*

O artigo “*Surprising Efficacy of Fine-Tuned Transformers for Fact-Checking over Larger Language Models*” (SETTY, 2024) faz um estudo no escopo de checagem de fatos por meio da estratégia de ajuste fino do *Transformer* XLM-RoBERTa-Large, e reportou bom desempenho na tarefa, ultrapassando o desempenho de alguns LLMs. Uma das etapas do experimento deste artigo consiste em realizar ajuste fino do *Transformer* XLM-RoBERTa-Large (CONNEAU *et al.*, 2019) para realizar a predição da veracidade de afirmações verificáveis. O artigo conclui, após seus experimentos, que o *Transformer* XLM-RoBERTa-Large obteve resultados surpreendentes para tarefas específicas de checagem de fatos em ambientes multilíngues, uma vez que o modelo obteve eficácia superior após o ajuste-fino quando comparado com o desempenho de LLMs maiores nas mesmas tarefas. A eficácia alcançada pelo modelo pode ser superior a diversas estratégias baseadas em engenharia de *prompts* com os modelos GPT-4 (OPENAI, 2025b), GPT-3.5-Turbo (OPENAI, 2025a) e Mistral-7b (JIANG *et al.*, 2023).

4. METODOLOGIA

Esta seção é responsável por definir e descrever o experimento elaborado para buscar as respostas das questões de pesquisa deste trabalho. Também é responsável por definir e descrever o *pipeline* e seus componentes desenvolvidos para a condução das instâncias do experimento.

4.1. ARQUITETURA

A arquitetura pensada para realização do experimento consiste em:

- **Componente para transformação de conjuntos de dados:** responsável pela aplicação das tarefas de extração e normalização de afirmações às entradas dos conjuntos de dados originais, a fim de obter os conjuntos de dados transformados que possibilitam a análise do desempenho das tarefas na classificação.

Este componente possui uma variável seletora que aplica apenas a tarefa de extração de afirmações, apenas a tarefa de normalização de afirmações ou as duas ao mesmo tempo;

- **Componente para ajuste-fino de *Transformers*:** responsável por realizar o ajuste-fino de um *Transformer* para realização da tarefa de classificação de fatos em verdadeiros ou falsos nos conjuntos de dados originais e transformados;
- **Componente para comparação de classificações:** responsável por comparar as classificações atribuídas às entradas pelos *Transformers* após o ajuste-fino, a fim de analisar casos em que os modelos passaram a acertar a classe de uma entrada após as tarefas de extração e normalização de afirmações, assim como os casos em que os modelos passaram a errar após elas;
- ***Scripts* auxiliares:** programas Python auxiliares responsáveis por tarefas como cálculo de métricas, geração de relatórios para análise de resultados, padronização dos nomes das classes dos conjuntos de dados conforme os critérios discutidos na Seção 4.2.3 e separação estratificada dos conjuntos de dados em subconjuntos de treino, validação e teste. A separação estratificada garante a manutenção da proporção das classes em todos os subconjuntos, evitando assim enviesamento dos resultados pela presença de classes desbalanceadas nos subconjuntos da base.

4.2. CONJUNTOS DE DADOS

Esta seção relata o processo de busca e seleção de conjuntos de dados no âmbito de checagem de fatos em português para condução dos experimentos desta pesquisa.

4.2.1. Busca por conjuntos de dados de checagem de fatos em português

O principal meio de busca por conjuntos de dados foi a pesquisa de artigos relacionados à checagem de fatos em português. Dois artigos foram selecionados como fontes principais de conjuntos de dados no âmbito de checagem de fatos em português.

A Seção “4.1.2 Coleta e Transformação de dados” do artigo “Explorando a Generalização de Classificadores de Notícias Falsas em Português Baseados em Modelos de Linguagem” (GUSMÃO, 2024) faz um levantamento de bases de dados disponíveis no âmbito da checagem de fatos em português e serviu como a primeira fonte de bases de dados para esta pesquisa.

O artigo fez um levantamento com os seguintes conjuntos de dados: BRACIS2019 (FAUSTINI; COVÕES, 2019); Central de Fatos (COUTO *et al.*, 2021); COVID19BR (MARTINS *et al.*, 2021); Factck.BR (MORENO; BRESSAN, 2019);




Figura 2 – Diagrama de arquitetura dos componentes do experimento.

Fake.Br (MONTEIRO *et al.*, 2018); FakeNewsSet (SILVA *et al.*, 2020); Fakepedia (CHARLES; RUBACK; OLIVEIRA, 2022); FakeRecogna (GARCIA; AFONSO; PAPA, 2022); FakeTweet.Br (CORDEIRO; PINHEIRO, 2019); e FakeWhatsApp.Br (CABRAL *et al.*, 2021).

Além do artigo mencionado acima, outro trabalho foi utilizado como base para a pesquisa de bases de dados para checagem de fatos em português brasileiro. A Seção “4.1. Panorama Geral e Tabela-Resumo das Bases” do artigo “Levantamento e Análise Qualitativa de Bases de Dados de Fake News em Português” (BARACHO; LISBOA; LOPES, 2025) também apresentou bons candidatos a conjuntos de dados para a pesquisa em seu levantamento, além de ter fornecido mais algumas informações sobre bases já citadas pelo primeiro artigo.

O artigo fez um levantamento com os seguintes conjuntos de dados: Base COVID-19 (TIGRE, 2023); Desinfopedia (GARCIA *et al.*, 2024); Factck.BR (MORENO; BRESSAN, 2019); Fake.Br (MONTEIRO *et al.*, 2018); FakeRecogna (GARCIA; AFONSO; PAPA, 2022); e FakeTrueBR (CHAVARRO *et al.*, 2023).

Nome	Ano	Classes	Instâncias	Fontes
Fake.Br	2018	Falsa	3600 (50%)	Diário do Brasil, A Folha do Brasil, The Journal Brasil, Top Five TV, G1, Folha de São Paulo e Estadão
		Verdadeira	3600 (50%)	
FakeTweet.Br	2019	Falsa	199 (67%)	Twitter
		Verdadeira	97 (33%)	

Tabela 3 – Bases de dados no âmbito de notícias falsas em português selecionadas para a condução dos experimentos desta pesquisa.

4.2.2. Escolha dos conjuntos de dados para realização do experimento

Ao analisar as bases levantadas, a primeira base a ser escolhida para o experimento foi a FakeTweet.Br (CORDEIRO; PINHEIRO, 2019). A base foi escolhida por ter seus textos extraídos do Twitter, o que faz com que os textos não tenham estrutura definida. Isso é uma característica fundamental para testar se as tarefas de extração e normalização de afirmações que buscam estruturar a afirmação terão um impacto significativo na acurácia de classificação em verdadeiro ou falso.

A segunda base selecionada para o experimento foi a Fake.Br (MONTEIRO *et al.*, 2018). Ao contrário da primeira base selecionada, os textos de entrada da classificação deste conjunto são bem mais estruturados, uma vez que foram extraídos de portais de notícias em vez de redes sociais. Contudo, mesmo que sejam melhor estruturados, os textos desta base são bem mais extensos do que os da primeira, com alguns exemplos ultrapassando os limites de tamanho de entrada dos *Transformers* selecionados para o experimento. Com isso, é possível verificar o impacto da sumarização associada às tarefas de extração e normalização de afirmações na atividade de classificação de fatos. Por meio da exploração de uma base como essa, é possível analisar o comportamento da classificação de textos maiores na checagem de fatos, em contraponto à natureza menor dos textos da primeira base.

Além do nível de estrutura e do tamanho das entradas dessas bases, a quantidade de instâncias de cada base também foi um fator determinante para a escolha delas. Como mostra a Tabela 3 conjunto FakeTweet.Br é pequeno, com um total de 299 entradas, enquanto o conjunto Fake.Br tem um tamanho médio, com 7200 entradas ao todo. Esta característica é interessante para explorar o que acontece com as métricas dos modelos após o ajuste-fino com bases de dimensões diferentes.

Observação: a escolha de conjuntos de dados se restringiu a estes dois por conta do tempo disponível para a realização da pesquisa, uma vez que selecionar mais conjuntos de dados acarretaria um crescimento rápido do número de experimentos que seriam realizados.

4.2.3. Padronização e pré-processamento dos conjuntos de dados

Com os conjuntos de dados que serão utilizados no experimento selecionados, um esforço de padronização foi realizado. A padronização é importante para que a transição da utilização de uma base de dados para a outra seja suave durante o experimento, submetendo assim as bases de dados sempre ao mesmo código durante o experimento. Com isso, reduz-se o risco de gerar algum resultado que tenha passado por um processo ligeiramente diferente do que o outro. As comparações e análises de resultados ficam focadas apenas nos resultados em si, sem se preocupar com possíveis diferenças de cada execução. Após a padronização, todas as colunas que representavam um mesmo dado entre os conjuntos, mas que possuíam um nome diferente, passaram a ter o mesmo nome. Por exemplo, todas as colunas que representam o rótulo de classificação foram renomeadas para “classificacao”.

Além disso, na etapa de ajuste-fino para classificação, é essencial ter a separação dos conjuntos de dados em subconjuntos de treino, validação e teste. Isso é importante para garantir que os modelos sejam treinados sempre sobre o mesmo subconjunto dos dados destinado ao treino, validados sempre sobre o mesmo subconjunto de validação e avaliados sempre sobre o mesmo subconjunto de dados destinado aos testes. Com isso, a separação da base em subconjuntos de treino, validação e teste foi realizada antes da transformação dos conjuntos de dados a partir das tarefas de extração e normalização de afirmações aplicadas às entradas e dos treinamentos de ajuste-fino, sempre respeitando e balanceando a porcentagem de exemplos de cada classe em cada subconjunto. O nome desse processo é estratificação e é essencial para que o modelo não se torne tendencioso a classificar as entradas mais para uma classe do que outra por conta da proporção desbalanceada entre os conjuntos de treino, validação e teste.

Por último, foi adicionado a cada conjunto de dados (tanto os originais quanto os transformados resultantes da aplicação das tarefas de extração e normalização de afirmações) uma coluna chamada “*custom_id*”, que serve para identificar e comparar cada entrada com suas entradas correspondentes nos outros conjuntos de dados. Assim, quando o texto de uma entrada mudar após passar por uma tarefa de normalização de afirmações, por exemplo, será possível comparar seu processamento nos diferentes modelos por meio deste identificador. O “*custom_id*” segue a seguinte lei de formação:

`custom_id: <nome_da_base>_<treino_ou_teste>_<indice_da_entrada>`

Assim, a quinta entrada da divisão de teste do conjunto de dados Fake.Br, por exemplo, terá seu “*custom_id*” igual a “*fakebr_test_5*”, tanto no conjunto de dados original quanto em seus respectivos conjuntos de dados transformados resultantes

da aplicação das tarefas de extração e normalização de afirmações.

4.3. LLMs

O objetivo desta seção é descrever o processo de pesquisa e decisão sobre quais LLMs utilizar para a transformação de conjuntos de dados resultante da aplicação de tarefas de extração e normalização de afirmações.

4.3.1. Busca e escolha de LLMs

A seleção de LLMs para a realização dos experimentos elaborados nesta pesquisa foi baseada na facilidade de acesso e popularidade entre as escolhas de LLMs para realização de tarefas de processamento de linguagem natural. Considerando o fácil acesso à *OpenAI Platform* (OPENAI, 2025e) e também sua popularidade, os LLMs escolhidos para compor o experimento foram escolhidos dentro das opções ofertadas pela OpenAI.

Ao final de uma análise levando em conta o custo de utilização dos modelos, foi decidido que os LLMs que seriam utilizados para realizar o experimento seriam o GPT-5 (OPENAI, 2025c) e o GPT-5 nano (OPENAI, 2025d).

Com o GPT-5 nano, o experimento recebe uma opção mais rápida, leve e mais barata para o processamento de requisições. Com o GPT-5, o experimento recebe uma opção com um raciocínio mais profundo. Isso é importante, pois a capacidade de raciocínio do modelo está diretamente ligada ao tamanho da cadeia de pensamentos que o modelo construirá para responder às perguntas (OPENAI, 2025g), e o uso de cadeia de pensamentos para simular os processos de raciocínio humano trouxe melhorias para a abordagem de normalização de afirmações proposta pela pesquisa (SUNDRIYAL; CHAKRABORTY; NAKOV, 2024). Essas são boas características para gerar diversos cenários para análise.

Observação: o experimento se baseou nos custos de processamento em lote dos modelos para construir seus componentes, por serem os menores dentre as opções de consumo.

4.4. TRANSFORMERS

Para a etapa de classificação de textos como verdadeiros ou falsos, os objetos que devem ser escolhidos são os modelos que serão utilizados. Neste caso, modelos com arquitetura *Transformer*, por apresentarem bons resultados na tarefa de classificação conforme a literatura citada na Seção 3.2, e porque o ajuste-fino de modelos desta arquitetura é uma alternativa menos custosa do que a classificação com o uso de LLMs.

4.4.1. Busca e escolha dos *Transformers* para ajuste fino para classificação de fatos

Como dito anteriormente na Seção 3.2, os resultados obtidos pelo artigo “*Surprising Efficacy of Fine-Tuned Transformers for Fact-Checking over Larger Language Models*” (SETTY, 2024) apontam o XLM-RoBERTa-Large como um bom candidato para a realização do experimento desta pesquisa.

O *Transformer* XLM-RoBERTa-Large é um modelo de linguagem mascarado multilíngue desenvolvido pela Facebook AI para melhorar significativamente a compreensão de linguagem *cross-lingual* com o pré-treinamento em uma escala massiva (CONNEAU *et al.*, 2019).

O *Transformer* BERTimbau também foi selecionado para compor os experimentos desta pesquisa por ser um modelo *encoder* amplamente utilizado e ajustado em tarefas de processamento de linguagem natural em português, que é justamente a natureza das tarefas desta pesquisa. Ele é baseado no modelo BERT (*Bidirectional Encoder Representations from Transformers*)(DEVLIN *et al.*, 2019), e é uma versão do modelo pré-treinado especificamente para o português brasileiro.

A pesquisa que deu origem ao BERTimbau foi motivada pela necessidade de recursos para processamento de linguagem natural para o português, que é um idioma com escassez de dados anotados, mas com abundância em dados não rotulados. O *Transformer* foi obtido por meio de um processo de ajuste-fino do BERT para, com a transferência de aprendizado, obter melhores desempenhos em tarefas de processamento de linguagem natural em português quando comparados a modelos multilíngues.

Com isso, os *Transformers* XLM-RoBERTa-Large e BERTimbau foram os escolhidos para serem submetidos ao ajuste-fino para classificação de afirmações no experimento, um pelo seu bom desempenho em tarefas de checagem de fato, até mesmo quando comparado com modelos muito maiores do que ele, o outro pelo seu bom desempenho em tarefas de processamento de linguagem natural em português brasileiro.

4.5. DEFINIÇÃO DOS PROMPTS

O processo de desenvolvimento do *prompt* para as tarefas de extração e normalização de afirmações foi realizado por meio da combinação de técnicas e ideias dos artigos citados e analisados na Seção 3.

Tanto o artigo que serviu de inspiração para a criação da tarefa no CheckThat! Lab do CLEF 2025 quanto os outros artigos também analisados na Seção 3 submetidos à competição mostraram como extrair resultados ótimos através de seus *prompts*.

Os *prompts* definidos para este experimento foram desenvolvidos nos moldes dos *prompts* das pesquisas mencionadas acima, com alguns ajustes após experimentações com a ferramenta *playground* da OpenAI *Platform* e análise intuitiva de resultados manuais sobre poucas entradas dos conjuntos de dados.

4.5.1. Prompt para Extração de Afirmações

A partir da definição da tarefa, do estudo da metodologia e resultados obtidos pelos artigos citados acima e de experimentos realizados na ferramenta *playground* da OpenAI *Platform*, o *prompt* final para a tarefa de extração de afirmações foi o seguinte:

Você é especialista em detecção de desinformação e checagem de fatos. Sua tarefa é ler textos e publicações de redes sociais potencialmente informais, desestruturados e desorganizados e extrair deles uma declaração clara e concisa, sem adicionar nenhuma informação nova, preservando sua linguagem original. Você receberá um texto de entrada e deve responder apenas à afirmação central extraída.

4.5.2. Prompt para Normalização de Afirmações

A partir da definição da tarefa, do estudo da metodologia e resultados obtidos pelos artigos citados acima e de experimentos realizados na ferramenta *playground* da OpenAI *Platform*, o *prompt* final para a tarefa de normalização de afirmações foi o seguinte:

Você é especialista em detecção de desinformação e checagem de fatos. Sua tarefa é ler textos e publicações de redes sociais potencialmente informais, desestruturados e desorganizados e normalizá-los em declarações claras e concisas, sem adicionar nenhuma informação nova, preservando sua linguagem original. Você receberá um texto de entrada e deve responder apenas à afirmação central normalizada, de modo que seja possível agrupar textos que abordam o mesmo assunto através de suas afirmações centrais normalizadas.

4.6. CONSTRUÇÃO DO EXPERIMENTO

A arquitetura do experimento foi definida através da divisão de suas etapas entre componentes, com o auxílio de alguns *scripts* escritos em Python para pré-processamento dos conjuntos de dados e geração de artefatos visuais e relatórios para facilitar o processo de análise. Cada componente é responsável por gerar uma parte dos resultados necessários para investigação acerca das questões de pesquisa propostas por este trabalho.

Na prática, cada componente foi implementado com Jupyter Notebook (PÉREZ; GRANGER, 2007), por ser uma ferramenta amplamente utilizada na construção de experimentos acadêmicos envolvendo programação por permitir a combinação de células de código executável com células de linguagens de marcação para anotações pertinentes.

O objetivo desta seção é justamente explicitar a construção de cada componente, ou seja, cada Jupyter Notebook que compõe o experimento, bem como seus *scripts* de apoio.

Observação: estes *notebooks* estão disponíveis publicamente no repositório associado a esta pesquisa, juntamente a todos os conjuntos de dados utilizados e todos os programas Python desenvolvidos ao longo desta pesquisa. O repositório pode ser acessado através da seguinte *URL*:

https://github.com/LuccaSabbatini/tcc_claim_extract_norm_check

4.6.1. Componente 1: transformação de conjuntos de dados a partir das tarefas de extração e normalização de afirmações

A ideia por trás deste componente é transformar os conjuntos de dados originais para o experimento. Seu funcionamento consiste basicamente em ler um conjunto de dados e, a partir dele, transformar este conjunto de dados através da passagem das entradas do conjunto original pela tarefa de extração de afirmações, de normalização de afirmações ou de ambas paralelamente.

O componente começa com a configuração da execução do experimento relativa: a qual LLM será selecionado para realização das tarefas; com quais parâmetros ele realizará as tarefas; e quais tarefas serão realizadas. Os parâmetros de configuração podem ser encontrados no Apêndice D deste artigo. Após a configuração da execução das transformações, o programa carrega o conjunto de dados na memória. Como não existe treinamento de nenhum modelo durante esta etapa, não existe separação do conjunto de dados em partições de treino, validação e teste, então o programa carrega todas as partições do conjunto de dados selecionado em um único *DataFrame* Pandas (MCKINNEY, 2010) e gera os “*custom_ids*” de cada entrada para possibilitar a referência e comparação dos resultados adiante, seguindo a lei de formação definida na Seção 4.2.3.

Por fim, o componente gera e submete os lotes de requisições associados às transformações das entradas do conjunto de dados para API da OpenAI para processamento. Quando o processamento dos lotes for finalizado, o componente faz o *download* dos resultados e os separa por tarefa (uma vez que estão misturados ao final do processamento). O componente separa os resultados agrupados por tarefas

em conjuntos de treino, validação e teste e salva em disco os novos conjuntos de dados transformados.

4.6.2. Componente 2: ajuste-fino dos *Transformers* para classificação de fatos

A ideia por trás deste componente é fazer o ajuste-fino dos *Transformers* para a tarefa de classificação de afirmações como verdadeiras ou falsas, treinando um *Transformer* em uma das versões dos conjuntos de dados selecionados para o experimento. Este processo consiste basicamente em adicionar uma camada de classificação ao final do modelo selecionado e treiná-la na versão selecionada dos conjuntos de dados disponíveis ao experimento para classificar frases em português em “verdadeiro” ou “falso”.

O componente define as configurações referentes às informações do *Transformer* selecionado para o processo de ajuste-fino e do conjunto de dados que será utilizado no treinamento e teste do *Transformer* (nome e versão do conjunto de dados).

Antes do treinamento, o componente carrega o tokenizador associado ao *Transformer* selecionado na memória e o configura para transformar os textos de entrada dos conjuntos de dados de treinamento, validação e teste em sequências de *tokens*, para que o *Transformer* possa interpretá-los. O tokenizador do experimento foi configurado para: truncar entradas maiores do que o tamanho máximo de entrada dos *Transformers*; converter *emojis* em texto através do uso da função *demojize* da biblioteca *emoji* (necessário quando as entradas são provenientes de conteúdos de redes sociais); preservar a coexistência de caracteres em caixa alta e caixa baixa; e normalizar acentos e caracteres Unicode.

O componente então carrega o conjunto de dados que será utilizado no treinamento, na validação e no teste e faz o mapeamento dos rótulos textuais “*true*” e “*fake*” para os valores 0 e 1 respectivamente, que são os valores utilizados pela camada de classificação que será posicionada ao final do *Transformer*. Como a classe “*fake*” foi mapeada como a classe positiva, os resultados falsos positivos e verdadeiros positivos no cálculo das métricas são referentes a classificações de entradas como “*fake*”. Por fim, os subconjuntos de treino, validação e teste são submetidos ao tokenizador para serem interpretados pelo *Transformer*.

Para o treinamento, o componente carrega o *Transformer* selecionado para o ajuste-fino na memória através da biblioteca *transformers* da Hugging Face, Inc. por meio de um objeto da classe *AutoModelForSequenceClassification*. Este método carrega o *Transformer* em questão, adicionando a ele a camada de classificação de maneira automática, passando por parâmetro a quantidade de rótulos diferentes, seus respectivos valores e identificadores.

As métricas escolhidas para avaliar os modelos e calculadas pela função no experimento são: acurácia, precisão, *f1* e *recall*. As definições destas métricas podem ser encontradas na Seção 2.1.4 deste artigo e, como dito anteriormente nesta seção, são referentes à classificação de instâncias como “fake”.

É criada então uma instância da classe *Trainer* da biblioteca *transformers*, que recebe como parâmetros: o modelo que será ajustado; os argumentos de treinamento (que se encontram no Apêndice E deste artigo); os conjuntos de dados de treinamento e teste devidamente pré-processados e tokenizados; o objeto do tokenizador; a função de cálculo de métricas; o *data collator*, responsável por transformar uma lista de exemplos tokenizados em um lote pronto para processamento do modelo; e um *callback* de parada precoce caso o modelo seja treinado por duas épocas consecutivas sem apresentar melhoras na métrica principal. O método “.train()” desta instância é chamado para dar início ao ajuste do modelo, e as métricas após cada época são exibidas na saída do *console* para possibilitar o acompanhamento do andamento do processo.

Ao final do treinamento, é feita a classificação do conjunto de testes com o melhor modelo resultante do ajuste-fino, e os resultados são armazenados em um arquivo CSV com as colunas “*custom_id*”, “*text*”, “*original_label*” e “*predicted_label*”. Estes arquivos possibilitarão a análise comparativa mais aprofundada do impacto das tarefas de extração e normalização de afirmações na classificação de todas as versões dos conjuntos de dados. As métricas do desempenho do modelo na classificação do subconjunto de teste também são salvas para análise.

Observação: este componente do experimento foi desenvolvido com base no material feito e disponibilizado pela professora orientadora desta pesquisa, durante sua disciplina da pós-graduação sobre Modelos de Linguagens Neurais.

4.6.3. Componente 3: análise dos casos de melhora ou piora na classificação de entradas específicas após as tarefas de extração e normalização de afirmações

Este é o terceiro e último componente principal, e a ideia por trás dele é fazer uma análise com uma granularidade menor do que simplesmente analisar métricas dos modelos após os ajustes-finos sobre os impactos das tarefas de extração e normalização de afirmações. Seu funcionamento consiste basicamente em analisar, para cada entrada da versão original de um conjunto de dados selecionado, como sua classificação foi realizada em todas as variações de ajuste-fino de *Transformers*.

A ideia é investigar exemplos que foram classificados **corretamente** por um *Transformer* quando treinado na versão original de um conjunto de dados, mas que foram classificados **incorretamente** por modelos treinados em bases transformadas a partir da aplicação das tarefas de extração e normalização de afirmações posterior-

mente. A investigação também se estende a exemplos classificados **incorretamente** por um *Transformer* quando treinado na versão original de um conjunto de dados, mas classificados de maneira **correta** por modelos treinados em bases transformadas posteriormente.

O relatório é gerado através do agrupamento de todas as classificações de todos os *Transformers* resultantes dos ajustes-finos para uma mesma entrada do conjunto de dados selecionado. Um arquivo CSV é gerado com as colunas “*custom_id*”, “*original_label*”, “*original_prediction*”, “*original_text*” e mais uma coluna para cada versão do conjunto de dados selecionado (Fake.Br ou FakeTweet.Br) formada pela combinação das tarefas (extração e normalização de afirmações) com os LLMs (GPT-5 nano e GPT-5), exceto a original. No caso deste experimento, além das colunas listadas acima, o arquivo de saída terá as seguintes colunas: “*claim_extraction_gpt-5-nano_prediction*”, “*claim_extraction_gpt-5_prediction*”, “*claim_normalization_gpt-5-nano_prediction*”, “*claim_normalization_gpt-5_prediction*”.

No caso deste experimento, cada relatório sobre os casos de melhora e piora dos ajustes finos de um dos *Transformers* treinado em um dos conjuntos de dados, o CSV será gerado com as colunas:

- ***custom_id***: representando o identificador da entrada dentro do experimento, seguindo as regras de formação especificadas em 4.2.3;
- ***original_label***: classificação original da entrada no conjunto de dados;
- ***original_prediction***: classificação dada pelo *Transformer* selecionado ao ser treinado na versão original do conjunto de dados;
- ***claim_extraction_gpt-5-nano_prediction***: classificação dada pelo *Transformer* selecionado ao ser treinado na versão de extração de afirmações feita pelo GPT-5 nano do conjunto de dados;
- ***claim_extraction_gpt-5_prediction***: classificação dada pelo *Transformer* selecionado ao ser treinado na versão de extração de afirmações feita pelo GPT-5 do conjunto de dados;
- ***claim_normalization_gpt-5-nano_prediction***: classificação dada pelo *Transformer* selecionado ao ser treinado na versão de normalização de afirmações feita pelo GPT-5 nano do conjunto de dados;
- ***claim_normalization_gpt-5_prediction***: classificação dada pelo *Transformer* selecionado ao ser treinado na versão de normalização de afirmações feita pelo GPT-5 do conjunto de dados;
- ***original_text***: texto original da entrada.

Observação: versões transformadas de conjuntos de dados geradas a partir do GPT-5 estão apenas disponíveis para a base FakeTweet.Br neste experimento. A base Fake.Br possui apenas versões transformadas do conjunto de dados geradas a partir do GPT-5 nano.

Por fim, o componente gera um relatório legível capaz de apontar quantas ocorrências de cada caso de melhora ou piora foram encontrados durante a análise das predições nos conjuntos de testes dos *Transformers* após ajuste-fino.

O relatório é um objeto JSON com as seguintes propriedades:

- ***dataset_name:*** conjunto de dados selecionado para a análise;
- ***model_name:*** *Transformer* selecionado para análise;
- ***incorrect_after_claim_extraction_gpt-5-nano_prediction:*** agrupa casos nos quais o modelo classificou a entrada corretamente quando treinado na base original, mas passou a classificá-la de maneira incorreta após a tarefa de extração de afirmações com o GPT-5 nano.
- ***incorrect_after_claim_extraction_gpt-5_prediction:*** agrupa casos nos quais o modelo classificou a entrada corretamente quando treinado na base original, mas passou a classificá-la de maneira incorreta após a tarefa de extração de afirmações com o GPT-5.
- ***incorrect_after_claim_normalization_gpt-5-nano_prediction:*** agrupa casos nos quais o modelo classificou a entrada corretamente quando treinado na base original, mas passou a classificá-la de maneira incorreta após a tarefa de normalização de afirmações com o GPT-5 nano.
- ***incorrect_after_claim_normalization_gpt-5_prediction:*** agrupa casos nos quais o modelo classificou a entrada corretamente quando treinado na base original, mas passou a classificá-la de maneira incorreta após a tarefa de normalização de afirmações com o GPT-5 nano.
- ***correct_after_claim_extraction_gpt-5-nano_prediction:*** agrupa casos nos quais o modelo classificou a entrada incorretamente quando treinado na base original, mas passou a classificá-la de maneira correta após a tarefa de extração de afirmações com o GPT-5 nano.
- ***correct_after_claim_extraction_gpt-5_prediction:*** agrupa casos nos quais o modelo classificou a entrada incorretamente quando treinado na base original, mas passou a classificá-la de maneira correta após a tarefa de extração de afirmações com o GPT-5.

- ***correct_after_claim_normalization_gpt-5-nano_prediction***: agrupa casos nos quais o modelo classificou a entrada incorretamente quando treinado na base original, mas passou a classificá-la de maneira correta após a tarefa de normalização de afirmações com o GPT-5 nano.
- ***correct_after_claim_normalization_gpt-5_prediction***: agrupa casos nos quais o modelo classificou a entrada incorretamente quando treinado na base original, mas passou a classificá-la de maneira correta após a tarefa de normalização de afirmações com o GPT-5.

Observação: cada propriedade que agrupa algum tipo de caso de melhora ou piora é um objeto JSON composto pelas seguintes propriedades:

- ***total***: total de ocorrências do caso de melhora ou piora em questão;
- ***ocurrences***: lista de objetos JSON, na qual cada elemento é uma linha do CSV de análise gerado pela célula anterior que se encaixa no caso de melhora ou piora em questão.

4.6.4. *Scripts* auxiliares

Para dar suporte ao pré-processamento dos conjuntos de dados e ao pós-processamento e análise dos resultados dos componentes principais do experimento, alguns *scripts* Python foram desenvolvidos. São eles:

- ***calculate_databases_metrics.py***: responsável por calcular as métricas relacionadas às entradas dos conjuntos de dados, que podem ser analisadas nas Tabelas 4 e 5;
- ***generate_fine_tuning_output_table.py***: responsável por gerar código LaTeX das tabelas com as métricas de cada ajuste fino realizada no experimento listadas no Apêndice F;
- ***split_train_test_sources.py***: responsável por separar os conjuntos de dados em subconjuntos de treino, validação e teste, sempre respeitando os critérios estabelecidos para uma divisão coerente de um conjunto de dados apontados na Seção 4.2.3;
- ***preprocess.py***: Como cada conjunto de dados possui um formato diferente, um *script* de padronização foi desenvolvido especificamente para cada conjunto de dados adotado pelo experimento para que todos os conjuntos de dados tenham os mesmos nomes de coluna para cada tipo de dado (por exemplo, todas as colunas que representam o rótulo de classificação foram renomeadas para “classificacao”).

4.7. FORMATO E EXECUÇÃO DO EXPERIMENTO

O experimento envolve diversos objetos, e isso introduz diversas variáveis. Dois LLMs (GPT-5 e GPT-5 nano) para a transformação dos conjuntos de dados, dois *Transformers* (BERTimbau e XLM-RoBERTa-Large) para o ajuste-fino para a classificação de fatos e dois conjuntos de dados para checagem de fatos (Fake.Br e FakeTweet.Br), com cada conjunto de dados tendo três versões (original e resultantes das execuções das tarefas de extração e normalização de afirmações nas entradas). Isso implica em um número razoável de combinações de experimentos.

Com a intenção de obter resultados capazes de direcionar a análise a conclusões mais fundamentadas, é necessário combinar estes elementos para ser possível acompanhar o comportamento de cada variável quando se muda cada elemento do experimento.

A seguir, a descrição de como cada elemento foi combinado para chegar a um formato de execução que gere observações valiosas quando comparadas com outras execuções.

4.7.1. Transformação de conjuntos de dados

No caso do conjunto de dados FakeTweet.Br, cada LLM foi combinada com as duas tarefas propostas para a transformação de conjuntos, ou seja, o GPT-5 e o GPT-5 nano foram combinados cada um com as tarefas de extração e normalização de afirmações, resultando em quatro conjuntos de dados transformados: extração de afirmações da base FakeTweet.Br com GPT-5; extração de afirmações da base FakeTweet.Br com GPT-5 nano; normalização de afirmações da base FakeTweet.Br com GPT-5; normalização de afirmações da base FakeTweet.Br com GPT-5 nano.

No caso do conjunto de dados Fake.Br, por ele ter um número maior de entradas e por conta das entradas terem um tamanho médio maior quando comparado com a base FakeTweet.Br, apenas o modelo GPT-5 nano foi utilizado para a transformação do conjunto de dados. Essa escolha foi feita pensando no custo financeiro do processamento de um conjunto de dados grande por um modelo com um preço de processamento mais elevado. Com isso, foram feitas duas transformações neste conjunto: aplicação da tarefa de extração de afirmações da base Fake.Br com o GPT-5 nano; aplicação da tarefa de normalização de afirmações da base Fake.Br com o GPT-5 nano.

Ao todo, há seis conjuntos de dados resultantes de transformações, totalizando oito conjuntos de dados totais contando com os originais de cada base de dados.

4.7.2. Ajuste-fino de *Transformers*

Em relação à etapa de ajuste-fino dos *Transformers* para a tarefa de classificação de fatos utilizando os conjuntos de dados citados acima, cada processo de ajuste-fino gera um modelo com métricas diferentes.

A fim de obter uma média das métricas dos processos de ajuste-fino dos modelos, cada combinação de *Transformer* com versão de um conjunto de dados foi treinada três vezes. Isto é, tanto o XLM-RoBERTa-Large como o BERTimbau passaram pelo processo de ajuste-fino três vezes para cada versão do conjunto de dados do experimento.

Recapitulando, é possível apontar que o experimento envolve:

- Dois *Transformers*, sendo eles o BERTimbau e o XLM-RoBERTa-Large;
- A base de dados FakeTweet.Br que possui cinco versões, sendo elas a Original, a baseada em extração de afirmações com GPT-5 nano, a baseada em extração de afirmações com GPT-5, a baseada em normalização de afirmações com GPT-5 nano e a baseada em normalização de afirmações com GPT-5;
- A base de dados Fake.Br que possui três versões, sendo elas a Original, a baseada em extração de afirmações com GPT-5 nano e a baseada em normalização de afirmações com GPT-5 nano.

Estes pontos implicam na existência de 16 combinações possíveis entre os *Transformers* e todas as versões dos dois conjuntos de dados. Ao treinar cada combinação três vezes, o experimento realiza um total de 48 treinamentos de ajuste fino.

Todos os treinamentos realizados neste experimento foram executados no mesmo computador. Os treinamentos foram feitos utilizando uma NVIDIA GeForce RTX 4060 Ti com 16 GB de VRAM.

4.7.3. Classificação dos conjuntos de teste para análise comparativa

Como explicado anteriormente na Seção 4.6.2, juntamente ao ajuste-fino dos *Transformers*, foram realizadas classificações sobre o conjunto de testes ao final dos treinamentos em cima de cada conjunto de dados. Esta coleta de classificações foi guardada para possibilitar a análise do impacto das tarefas de extração e normalização de afirmações na classificação do mesmo dado de entrada original explicada na Seção 4.6.3.

Cada comparação de classificações é construída em função da quantidade de versões que um conjunto de dados possui. Isso se dá por conta da comparação das classificações geradas pelos *Transformers* ajustados para cada versão do conjunto de dados.

No contexto do experimento, a base FakeTweet.Br tem cinco versões: original; extração de afirmações (GPT-5 nano); extração de afirmações (GPT-5); normalização de afirmações (GPT-5 nano); normalização de afirmações (GPT-5). Diferentemente da base FakeTweet.Br, a base Fake.Br possui apenas três versões: original; extração de afirmações (GPT-5 nano); normalização de afirmações (GPT-5 nano).

Como as comparações devem ser geradas para cada *Transformer* e o experimento é realizado para os *Transformers* BERTimbau e XLM-RoBERTa-Large, o conjunto de dados FakeTweet.Br gerará dez comparações, enquanto o conjunto Fake.Br gerará seis.

Cada relatório analisa uma combinação de *Transformer* com uma base de dados, ou seja, as 16 combinações citadas acima gerarão quatro relatórios: BERTimbau com FakeTweet.Br; BERTimbau com Fake.Br; XLM-RoBERTa-Large com FakeTweet.Br; XLM-RoBERTa-Large com Fake.Br.

5. ANÁLISE DE RESULTADOS

Após a execução do experimento para todas as combinações propostas, o próximo passo é a análise dos resultados obtidos para buscar respostas para as questões de pesquisa do trabalho.

5.1. INFORMAÇÕES DAS ENTRADAS DOS CONJUNTOS DE DADOS UTILIZADOS E TRANSFORMADOS PELO EXPERIMENTO

A Tabelas 4 e 5 abaixo investigam e destacam os formatos dos conjuntos de dados utilizados e transformados pelo experimento.

FakeTweet.Br					
Métrica	Original	<i>Claim Extraction</i>		<i>Claim Normalization</i>	
		GPT-5 nano	GPT-5	GPT-5 nano	GPT-5
Média de caracteres por entrada	206,78	87,68	94,83	112,77	96,47
Média de palavras por entrada	29,65	15,30	16,28	19,05	16,58

Tabela 4 – Métricas dos conjuntos de dados baseados no FakeTweet.Br.

Mesmo em conjuntos de dados diferentes como o FakeTweet.Br e o Fake.Br, tanto por conta da ausência de estrutura nos textos de um e presença de estrutura nos textos do outro quanto pela quantidade de entradas muito discrepante entre eles, as Tabelas 4 e 5 em todos os casos os conjuntos de dados transformados a partir da aplicação da tarefa de normalização de afirmações resultaram em médias de caracteres e palavras por entrada maiores quando comparados com os conjuntos

Métrica	Original	Fake.Br	
		<i>Claim Extraction</i> GPT-5 nano	<i>Claim Normalization</i> GPT-5 nano
Média de caracteres por entrada	2827,33	116,87	265,14
Média de palavras por entrada	366,44	16,72	40,15

Tabela 5 – Métricas dos conjuntos de dados baseados no Fake.Br.

transformados pela aplicação da tarefa de extração de afirmações. Isso implica que os LLMs são capazes de diferenciar as características diferentes das tarefas, uma vez que, em geral, o LLM faz algum tipo de reescrita da afirmação central de uma entrada na tarefa de normalização de afirmações após identificar qual é a afirmação central, que resulta em médias maiores de caracteres e palavras por entrada quando se compara com as médias da tarefa de extração de afirmação.

Observação: todos os conjuntos de dados originais e resultantes de transformação utilizados nesta pesquisa podem ser encontrados no diretório “/data/” na raiz do repositório associado a esta pesquisa, que pode ser acessado através da seguinte *URL*:

https://github.com/LuccaSabbatini/tcc_claim_extract_norm_check/

5.2. ANÁLISE DE EXEMPLOS DOS CONJUNTOS DE DADOS

A seguir, a análise de uma instância de entrada de cada conjunto de dados selecionado para o experimento ao lado de todas as suas variações derivadas das combinações entre as tarefas de extração e normalização de afirmações e os LLMs GPT-5 nano e GPT-5.

Input: faketweetbr_train_157

Original: PRAIA VERMELHA, vizinha ao Morro da Urca , virando praia de nudismo ...!!!* A intenção é afrontar os militares, que têm unidades nessa praia, esperando uma represália, para que haja um confronto e então chamar os militares de gorilas truculentos. Tudo orquestrado por PT, Psol PCdoB

Extração de afirmações (GPT-5 nano): A intenção é afrontar os militares, que têm unidades nessa praia, esperando uma represália, para que haja um confronto e então chamar os militares de gorilas truculentos. Tudo orquestrado por PT, Psol PCdoB

Extração de afirmações (GPT-5): PRAIA VERMELHA, vizinha ao Morro da Urca, virando praia de nudismo para afrontar os militares, que têm unidades nessa praia, esperando uma represália, para que haja um confronto e então chamar os militares de gorilas truculentos, tudo orquestrado por PT, Psol PCdoB.

Normalização de afirmações (GPT-5 nano): Afirma que a Praia Vermelha, vizinha ao Morro da Urca, está virando praia de nudismo, com a intenção de afrontar os militares, que têm unidades nessa praia, esperando uma represália para que haja um confronto e então chamar os militares de gorilas truculentos, tudo orquestrado por PT, Psol PCdoB.

Normalização de afirmações (GPT-5): A Praia Vermelha está virando praia de nudismo para afrontar os militares que têm unidades nessa praia, esperando uma represália para que haja um confronto e então chamar os militares de gorilas truculentos, tudo orquestrado por PT, Psol e PCdoB.

Input: fakebr_train_67

Original: questao segundos passageiros sentiram tontura desmaiaram voo empresa aerea american airlines forçado aterrissar membros tripulacao passageiros atingidos doenca misteriosa voo saiu galeao rio janeiro destino miami aviao desceu distrito federal algumas pessoas comecaram passar mal informacao confirmada inframerica empresa administra aeroporto internacional brasilia aviao decolou rio janeiro testemunhas disseram quatro pessoas queixaram tontura tambem acabou ocasionando desmaios caso parecido fato ocorreu tripulantes passageiros tambem atingidos doenca misteriosa causou desmaios durante voo ia londres los angeles

Extração de afirmações (GPT-5 nano): Algumas pessoas a bordo de um voo da american airlines entre o Rio de Janeiro e Miami sentiram tontura e desmaiaram por doenca misteriosa, levando o voo a ser forçado a aterrissar.

Normalização de afirmações (GPT-5 nano): Voo da American Airlines, do Galeão (Rio de Janeiro) com destino a Miami, foi forçado a aterrar no Distrito Federal devido a uma doença misteriosa que atingiu passageiros e tripulação, causando tonturas e desmaios; pelo menos quatro pessoas relataram tontura.

Estes exemplos foram selecionados e destacados para olhar um pouco mais de perto e ter um modelo mental melhor de como foram os resultados transformados pelos LLMs.

Ao analisar as saídas de maneira comparativa, é possível identificar as diferentes características nos resultados de cada tarefa apontadas na Seção 1.2. É possível observar a extração de um trecho ou um fragmento do texto inteiro analisado sem modificação, ou com modificações mínimas no caso dos resultados das tarefas de extração de afirmações e a geração de uma afirmação concisa, direto ao ponto, verificável e autocontida no caso dos resultados das tarefas de normalização de afirmações.

5.3. MÉTRICAS DOS MODELOS RESULTANTES DOS AJUSTES FINOS DOS TRANSFORMERS

A Tabelas 6, 7, 8 e 9 abaixo listam as médias das métricas dos melhores modelos resultantes dos três ajustes-finos realizados de cada *Transformer* sobre todas as versões de cada conjunto de dados.

Todas as linhas das tabelas de métricas possuem um valor destacado em negrito. Este valor destacado é a melhor média daquela métrica para os ajustes finos do *Transformer* em questão para a classificação do conjunto de teste da base de dados em questão.

Após analisar as métricas dos modelos resultantes dos ajustes finos dos *Transformers* pelas Tabelas 6, 7, 8 e 9, é possível observar que os treinamentos feitos com

XLM-RoBERTa-Large — FakeTweet.Br					
Métrica	Original	<i>Claim Extraction</i>		<i>Claim Normalization</i>	
		GPT-5 nano	GPT-5	GPT-5 nano	GPT-5
Perda	0,318	0,357	0,500	0,333	0,423
Acurácia	0,859	0,859	0,778	0,896	0,807
Precisão	0,881	0,886	0,811	0,906	0,812
Recall	0,949	0,929	0,949	0,960	0,970
F1	0,910	0,906	0,865	0,931	0,882

Tabela 6 – Médias das métricas dos melhores modelos de cada um dos três ajustes-finos do *Transformer* XLM-RoBERTa-Large na classificação do conjunto de testes de todas as variações do conjunto de dados FakeTweet.Br.

XLM-RoBERTa-Large — Fake.Br			
Métrica	Original	<i>Claim Extraction</i>	<i>Claim Normalization</i>
		GPT-5 nano	GPT-5 nano
Perda	0,160	0,618	0,467
Acurácia	0,955	0,637	0,816
Precisão	0,954	0,688	0,843
Recall	0,961	0,455	0,794
F1	0,957	0,523	0,817

Tabela 7 – Médias das métricas dos melhores modelos de cada um dos três ajustes-finos do *Transformer* XLM-RoBERTa-Large na classificação do conjunto de testes de todas as variações do conjunto de dados Fake.Br.

BERTimbau — FakeTweet.Br					
Métrica	Original	<i>Claim Extraction</i>		<i>Claim Normalization</i>	
		GPT-5 nano	GPT-5	GPT-5 nano	GPT-5
Perda	0,191	0,321	0,332	0,342	0,290
Acurácia	0,933	0,881	0,874	0,881	0,874
Precisão	0,927	0,876	0,910	0,874	0,896
Recall	0,990	0,980	0,919	0,980	0,939
F1	0,957	0,924	0,914	0,924	0,916

Tabela 8 – Médias das métricas dos melhores modelos de cada um dos três ajustes-finos do *Transformer* BERTimbau na classificação do conjunto de testes de todas as variações do conjunto de dados FakeTweet.Br.

BERTimbau — Fake.Br			
Métrica	Original	<i>Claim Extraction</i>	<i>Claim Normalization</i>
		GPT-5 nano	GPT-5 nano
Perda	0,121	0,488	0,417
Acurácia	0,969	0,761	0,819
Precisão	0,968	0,780	0,860
Recall	0,973	0,754	0,780
F1	0,971	0,765	0,816

Tabela 9 – Médias das métricas dos melhores modelos de cada um dos três ajustes-finos do *Transformer* BERTimbau na classificação do conjunto de testes de todas as variações do conjunto de dados Fake.Br.

os conjuntos de dados transformados pelas tarefas de extração e normalização de afirmações não resultaram em modelos com métricas melhores para classificação de fatos como verdadeiros ou falsos, com exceção da normalização de afirmações com o GPT-5 nano para o XLM-RoBERTa-Large.

Para a base de dados Fake.Br, o *Transformer* XLM-RoBERTa-Large obteve resultados muito piores quando ajustado e analisado a partir dos conjuntos de dados transformados. Todas as métricas foram menores quando comparadas com as métricas obtidas com a versão original do conjunto, tanto para extração quanto para normalização de afirmações. Contudo, as métricas relacionadas à tarefa de normalização de afirmações obtiveram resultados levemente melhores do que os resultados da tarefa de extração de afirmações. O mesmo pode ser dito sobre o *Transformer* BERTimbau ao analisar os resultados obtidos com a base de dados Fake.Br. Os melhores resultados também foram os obtidos com o conjunto original e a tarefa de normalização de afirmações gerou resultados levemente superiores aos encontrados pela tarefa de extração de afirmações.

O BERTimbau também obteve resultados nesta linha para a base FakeTweet.Br. Os melhores resultados também foram os obtidos com o conjunto original, porém não houve tanta diferença entre as métricas relacionadas às tarefas de extração e as métricas relacionadas às tarefas de normalização, como foi o caso na análise dos resultados da base de dados Fake.Br. O único caso no qual as melhores métricas não foram aquelas correspondentes ao ajuste e teste dos *Transformers* com a versão original da base de dados foi o caso do ajuste e teste do XLM-RoBERTa-Large sobre o conjunto de dados com afirmações normalizadas pelo GPT-5 nano do FakeTweet.Br. Todas as métricas foram melhores neste caso, com exceção da perda, que foi levemente menor no conjunto de testes original, e o *recall* que foi levemente maior no conjunto de testes da tarefa de normalização de afirmações com o GPT-5.

Ao analisar estes resultados, é possível perceber que o *Transformer* BERTimbau treinado para realizar tarefas de processamento de linguagem natural em por-

tuguês brasileiro não ganha desempenho na classificação de fatos sem recuperação de evidências em português quando se aplicam as tarefas de extração e normalização feitas por LLMs às entradas. Já no caso do XLM-RoBERTa-Large, que é um modelo *Transformer* multilíngue, a tarefa de normalização de afirmações se mostrou como um caminho para melhorar o desempenho do modelo na classificação de fatos em português no escopo sem recuperação de evidências. Também é possível perceber que um LLM menor é capaz de realizar a tarefa de normalização de afirmações a fim de ganhar desempenho na classificação, uma vez que os resultados da classificação da normalização de afirmações das entradas foram melhores com o GPT-5 nano do que com o GPT-5.

Com isso, é possível observar que as tarefas de extração e normalização de afirmações em geral diminuem o desempenho de *Transformers* ajustados para a classificação de fatos como verdadeiros ou falsos em português sem recuperação de evidências.

5.4. ANÁLISE DOS CASOS DE MELHORA OU PIORA NA CLASSIFICAÇÃO DE ENTRADAS ESPECÍFICAS APÓS AS TAREFAS DE EXTRAÇÃO E NORMALIZAÇÃO DE AFIRMAÇÕES

As Tabelas 10, 11, 12 e 13 a seguir listam as informações obtidas pelos relatórios gerados pelo componente do experimento explorado e explicado na Seção 4.6.3.

XLM-RoBERTa-Large — FakeTweet.Br	
Descrição do caso	Contagem
Classificação correta após extração com GPT-5 nano	4
Classificação incorreta após extração com GPT-5 nano	7
Classificação correta após extração com GPT-5	3
Classificação incorreta após extração com GPT-5	5
Classificação correta após normalização com GPT-5 nano	2
Classificação incorreta após normalização com GPT-5 nano	2
Classificação correta após normalização com GPT-5	3
Classificação incorreta após normalização com GPT-5	6

Tabela 10 – Contagem de casos de melhora e piora na classificação das entradas do conjunto de dados FakeTweet.Br após os ajustes-finos do *Transformer* XLM-RoBERTa-Large com as versões da base resultantes das execuções das tarefas de extração e normalização de afirmações sobre a versão original.

Ao analisar as Tabelas 10 e 12 referentes ao conjunto de dados FakeTweet.Br é observável que os modelos resultantes dos ajustes-finos dos *Transformers* ficaram com um saldo negativo na tentativa de melhorar classificações erradas em relação

XLM-RoBERTa-Large — Fake.Br	
Descrição do caso	Contagem
Classificação correta após extração com GPT-5 nano	14
Classificação incorreta após extração com GPT-5 nano	353
Classificação correta após normalização com GPT-5 nano	15
Classificação incorreta após normalização com GPT-5 nano	113

Tabela 11 – Contagem de casos de melhora e piora na classificação das entradas do conjunto de dados Fake.Br após os ajustes-finos do *Transformer* XLM-RoBERTa-Large com as versões da base resultantes das execuções das tarefas de extração e normalização de afirmações sobre a versão original.

BERTimbau — FakeTweet.Br	
Descrição do caso	Contagem
Classificação correta após extração com GPT-5 nano	1
Classificação incorreta após extração com GPT-5 nano	3
Classificação correta após extração com GPT-5	3
Classificação incorreta após extração com GPT-5	6
Classificação correta após normalização com GPT-5 nano	1
Classificação incorreta após normalização com GPT-5 nano	1
Classificação correta após normalização com GPT-5	3
Classificação incorreta após normalização com GPT-5	3

Tabela 12 – Contagem de casos de melhora e piora na classificação das entradas do conjunto de dados FakeTweet.Br após os ajustes-finos do *Transformer* BERTimbau com as versões da base resultantes das execuções das tarefas de extração e normalização de afirmações sobre a versão original.

BERTimbau — Fake.Br	
Descrição do caso	Contagem
Classificação correta após extração com GPT-5 nano	6
Classificação incorreta após extração com GPT-5 nano	165
Classificação correta após normalização com GPT-5 nano	7
Classificação incorreta após normalização com GPT-5 nano	117

Tabela 13 – Contagem de casos de melhora e piora na classificação das entradas do conjunto de dados Fake.Br após os ajustes finos do *Transformer* BERTimbau com as versões da base resultantes das execuções das tarefas de extração e normalização de afirmações sobre a versão original.

aos *Transformers* treinados nas versões originais das bases. O XLM-RoBERTa-Large teve 12 classificações corretas e 20 incorretas após as tarefas de extração e normalização de afirmações. O BERTimbau teve 8 classificações corretas e 13 incorretas após as tarefas. Isto significa que, após a aplicação das tarefas de extração e normalização de afirmações, os modelos conjuntamente ganharam 20 e perderam 33 classificações quando comparados com os resultados da classificação do conjunto de testes sem transformações. O saldo dos resultados das classificações nas versões transformadas do conjunto de dados FakeTweet.Br é negativo, com 13 classificações perdidas quando comparados com a classificação da versão original do conjunto de testes da base de dados.

A mesma análise pode ser feita para a base Fake.Br, através das Tabelas 11 e 13. O XLM-RoBERTa-Large teve apenas 29 classificações corretas e 466 incorretas após as tarefas de extração e normalização de afirmações. O BERTimbau teve 13 classificações corretas e 282 incorretas após as tarefas. Isto significa que, após a aplicação das tarefas de extração e normalização de afirmações, os modelos conjuntamente ganharam 42 e perderam 748 classificações quando comparados com os resultados da classificação do conjunto de testes sem transformações. O saldo dos resultados das classificações nas versões transformadas do conjunto de dados Fake.Br é negativo, com 706 classificações perdidas quando comparados com a classificação da versão original do conjunto de testes da base de dados.

6. CONCLUSÃO

Como dito anteriormente, a motivação desta pesquisa é estudar a aplicação e analisar os resultados das tarefas de extração e normalização de afirmações em publicações de redes sociais através do uso de LLMs para fortalecer checagem de fatos em português. A partir disso, questionou-se se as tarefas de extração e normalização de afirmações melhoram ou não a classificação de fatos em português pelos modelos *Transformer* ajustados em um contexto sem recuperação de evidências. Para responder a estas perguntas, foram desenvolvidos programas para transformar conjuntos de dados em português a partir da aplicação das tarefas de extração e normalização de afirmações, fazer o ajuste-fino de *Transformers* para a tarefa de classificação sobre esses conjuntos de dados e para analisar e comparar os resultados das classificações de cada combinação de tarefa, conjunto de dados e *Transformer*.

Em suma, após obter e analisar os resultados obtidos nesta pesquisa, conclui-se que as tarefas de extração e normalização de afirmações a partir de LLMs não só geralmente não resultam em melhora para a classificação de fatos em português feita através do ajuste-fino de modelos *Transformer* em um ambiente sem recuperação de evidências, mas também diminuem o desempenho destes modelos quando comparados com o treinamento e classificação em bases de dados sem esse tipo de trans-

formação. Porém, é importante salientar que, mesmo que nem a extração e nem a normalização de afirmações tenham melhorado o desempenho dos *Transformers* na tarefa de classificação, a tarefa de normalização de afirmações em geral mostrou resultados melhores quando comparada com a tarefa de extração de afirmações.

Finalmente, mesmo diante dos resultados obtidos neste trabalho, o estudo da utilização das tarefas de extração e normalização das afirmações centrais de uma publicação de rede social para recuperação de evidências para suportá-las é um ponto interessante para ser explorado.

6.1. AMEAÇAS À VALIDADE

Embora a pesquisa tenha sido realizada sempre com o objetivo de minimizar o enviesamento dos resultados ocasionados pela construção não ideal do experimento ou pela manipulação dos dados de entrada, algumas escolhas do experimento podem, sim, ter influenciado a conclusão.

6.1.1. Validade interna

Outro fator que pode ter afetado os resultados é a escolha da estratégia de tratamento de entradas muito grandes na etapa de ajuste-fino dos *Transformers*. No caso em que uma entrada é grande demais para ser processada pelo *Transformer* na etapa de classificação de afirmações, a decisão tomada para passar por este problema foi o truncamento do texto de entrada. Isso não é o ideal, uma vez que a abordagem pode ser substituída pela implementação de uma janela móvel de processamento da entrada para realizar a classificação em mais de uma passagem pelo modelo. O truncamento foi escolhido como estratégia a fim de simplificar a implementação do experimento.

Porém, mesmo com a simplificação do experimento em algumas etapas, o cuidado da pesquisa ao separar conjuntos de treino, validação e teste das bases de dados, levando em consideração as distribuições das classes e temas dos textos de entrada, tenta mitigar em algum nível o enviesamento dos resultados.

6.1.2. Validade externa

Talvez a maior questão quanto à generalização das conclusões encontradas neste estudo esteja relacionada ao fato do conjunto Fake.Br, que possui o maior número de instâncias entre os dois selecionados para conduzir o experimento, e só foi utilizado para transformar conjuntos de dados com o uso do GPT-5 nano. Tanto a utilização do GPT-5 para possibilitar a comparação com o GPT-5 nano dentro do mesmo conjunto de dados (como acontece no caso do FakeTweet.Br) quanto a exploração de outros LLMs fora da OpenAI são pontos que com certeza somariam

muito às conclusões do estudo, mas que não puderam ser explorados por questões relacionadas a custo elevado de utilização.

Quanto à generalização dos resultados do experimento para fora dele, é importante ressaltar que tanto a quantidade dos conjuntos de dados selecionados para a realização do experimento quanto o tamanho de um deles (FakeTweet.Br) não são ideais para chegar a uma conclusão generalizada por conta própria quanto ao impacto das tarefas de extração e normalização de afirmações na tarefa de classificação de fatos.

Além disso, os conjuntos de dados utilizados no experimento são mais antigos e podem estar datados. Isso também se dá pela escassez de conjuntos de dados no escopo de classificação de fatos em português que utilizam textos de redes sociais.

Mesmo assim, a seleção dos dois conjuntos de dados utilizados pelo experimento ofereceu em algum nível a possibilidade de enxergar observações pertinentes no contexto de como pode ser o impacto das tarefas de extração e normalização de afirmações discutidas neste artigo em um cenário real em português.

6.2. TRABALHOS FUTUROS

Várias ideias para trabalhos futuros surgiram ao longo da realização do experimento, seja no âmbito de expandir os resultados obtidos do experimento através da exploração de resultados com outros LLMs, outros *Transformers* e outras bases de dados, ou no âmbito de agregar mais etapas ao experimento.

No quesito de expandir o leque de resultados para comparação, a exploração dos conjuntos de dados MuMin (NIELSEN; MCCONVILLE, 2022) e FakeRecognia (GARCIA; AFONSO; PAPA, 2022) parece ser promissora para o aprofundamento da investigação das hipóteses da pesquisa. Outra possibilidade de expansão neste quesito é a utilização prioritária do GPT-5 e de outros LLMs maiores do que o GPT-5 nano para realizar a tarefa de normalização de afirmações, uma vez que tal combinação mostrou ter potencial ao longo da análise dos resultados do experimento.

No quesito de expansão do experimento em si, seria interessante explorar a substituição de LLMs pelo ajuste-fino de *Transformers* na etapa de transformação dos conjuntos dados. Outra oportunidade de expansão seria a análise dos resultados ao executar a tarefa de normalização de afirmações sobre um conjunto de dados transformado através da aplicação da tarefa de extração de afirmações, concatenando as duas tarefas. Também seria interessante analisar os resultados que uma combinação composta por uma extração de afirmações seguida de uma normalização de afirmações pode trazer. Também seria interessante a realização de uma nova bateria de experimentos para analisar aspectos que não foram muito bem explorados nesta primeira análise, como a diferença dos custos financeiros das tarefas de extração e normalização por cada LLM e as diferenças de tempo no treino e na

inferência entre as diversas combinações de modelos *Transformer* e bases de dados, pois mesmo que tenha sido observado que os conjuntos de dados transformados resultaram em treinamentos e inferências mais rápidos (o que pode ser uma vantagem), estes dados não foram coletados e analisados de maneira criteriosa. Outro ponto importante para explorar em um trabalho futuro é a continuação do desenvolvimento e teste dos *prompts* das tarefas de transformação, além da elaboração de uma maneira de medir a qualidade das transformações a fim de garantir qualidade nos resultados das tarefas. Por fim, seria interessante integrar uma de extração e normalização de afirmações a algum *pipeline* de verificação de fatos robusto, com componentes para recuperação de evidências. Assim, seria possível avaliar o impacto das tarefas de extração e normalização de afirmações na qualidade e relevância das evidências recuperadas e na acurácia da classificação de fatos em um ambiente mais desenvolvido e estabelecido.

Referências

ALLCOTT, H.; GENTZKOW, M. Social media and fake news in the 2016 election. *Journal of Economic Perspectives*, v. 31, n. 2, p. 211–36, May 2017. Disponível em: <https://www.aeaweb.org/articles?id=10.1257/jep.31.2.211>.

ALMADA, F. L. N. *et al.* AKCIT-FN at CheckThat! 2025: Switching Fine-Tuned SLMs and LLM Prompting for Multilingual Claim Normalization. 2025. Disponível em: <https://arxiv.org/abs/2509.11496>.

ANIKINA, T. *et al.* dfkinit2b at checkthat! 2025: Leveraging llms and ensemble of methods for multilingual claim normalization. In: . [s.n.]. Disponível em: <https://api.semanticscholar.org/CorpusID:281748198>.

BARACHO, J.; LISBOA, L.; LOPES, R. Levantamento e análise qualitativa de bases de dados de fake news em português. In: *Anais do VI Workshop sobre as Implicações da Computação na Sociedade*. Porto Alegre, RS, Brasil: SBC, 2025. p. 169–180. ISSN 2763-8707. Disponível em: <https://sol.sbc.org.br/index.php/wics/article/view/35944>.

CABRAL, L. *et al.* Fakewhatsapp.br: Nlp and machine learning techniques for misinformation detection in brazilian portuguese whatsapp messages. In: *ICEIS*. [S.l.: s.n.], 2021. v. 1, p. 63–74.

CASELI, H. M.; NUNES, M. G. V. (Ed.). *Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português*. 3. ed. BPLN, 2024. ISBN 978-65-01-20581-6. Disponível em: <https://brasileiraspln.com/livro-pln/3a-edicao/>.

CHARLES, A. C.; RUBACK, L.; OLIVEIRA, J. Fakepedia corpus: A flexible fake news corpus in portuguese. In: *International Conference on Computational Processing of the Portuguese Language*. [S.l.]: Springer, 2022. p. 37–45.

CHAVARRO, J. *et al.* Faketruebr: Um corpus brasileiro de notícias falsas. In: *Anais da XVIII Escola Regional de Banco de Dados*. Porto Alegre, RS, Brasil: SBC, 2023. p. 108–117. ISSN 2595-413X. Disponível em: <https://sol.sbc.org.br/index.php/erbd/article/view/24352>.

CLEF. *CheckThat! Lab at CLEF 2025*. 2025. <https://checkthat.gitlab.io/clef2025/>. Acessado em: 16/11/2025.

CLEF. *CheckThat! Lab at CLEF 2025 - Task 2*. 2025. <https://checkthat.gitlab.io/clef2025/task2/>. Acessado em: 16/11/2025.

CLEF. *Conference and Labs of the Evaluation Forum (CLEF)*. 2025. <https://www.clef-initiative.eu/>. Acessado em: 16/11/2025.

CONNEAU, A. *et al.* Unsupervised cross-lingual representation learning at scale. *CoRR*, abs/1911.02116, 2019. Disponível em: <http://arxiv.org/abs/1911.02116>.

CORDEIRO, P. R.; PINHEIRO, V. Um corpus de notícias falsas do twitter e verificação automática de rumores em língua portuguesa. In: *PROCEEDINGS of*

the Symposium in Information and Human Language Technology. [S.l.: s.n.], 2019. p. 219–228.

COSTA-LUIS, C. da. tqdm: A fast, extensible progress meter for python and cli. *Journal of Open Source Software*, v. 4, p. 1277, 05 2019.

COUTO, J. M. M. *et al.* Central de fatos: Um repositório de checagens de fatos. In: SBC. *Anais do III Dataset Showcase Workshop*. [S.l.], 2021. p. 128–137.

DEVLIN, J. *et al.* *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. 2019. Disponível em: [⟨https://arxiv.org/abs/1810.04805⟩](https://arxiv.org/abs/1810.04805).

DOURADO, T. M. S. G. Fake news na eleição presidencial de 2018 no brasil. Instituto de Humanidades, Artes e Ciências Professor Milton Santos, 2020.

DUCHI, J.; HAZAN, E.; SINGER, Y. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research*, v. 12, n. 61, p. 2121–2159, 2011. Disponível em: [⟨http://jmlr.org/papers/v12/duchi11a.html⟩](http://jmlr.org/papers/v12/duchi11a.html).

FATOS, A. *Aos Fatos*. 2025. [⟨https://www.aosfatos.org/⟩](https://www.aosfatos.org/). Organização jornalística dedicada ao combate à desinformação.

FAUSTINI, P.; COVÕES, T. Fake news detection using one-class classification. In: IEEE. *2019 8th Brazilian Conference on Intelligent Systems (BRACIS)*. [S.l.], 2019. p. 592–597.

GARCIA, G. L.; AFONSO, L. C. S.; PAPA, J. a. P. Fakerecogna: A new brazilian corpus for fake news detection. In: *International Conference on Computational Processing of the Portuguese Language*. [S.l.]: Springer, 2022. p. 57–67.

GARCIA, G. L. *et al.* Text summarization and temporal learning models applied to Portuguese fake news detection in a novel Brazilian corpus dataset. In: GAMALLO, P. *et al.* (Ed.). *Proceedings of the 16th International Conference on Computational Processing of Portuguese - Vol. 1*. Santiago de Compostela, Galicia/Spain: Association for Computational Linguistics, 2024. p. 86–96. Disponível em: [⟨https://aclanthology.org/2024.propor-1.9/⟩](https://aclanthology.org/2024.propor-1.9/).

GUSMÃO, C. E. Explorando a generalização de classificadores de notícias falsas em português baseados em modelos de linguagem. Universidade Federal Fluminense, 2024.

HARRIS, C. R. *et al.* Array programming with NumPy. *Nature*, Springer Science and Business Media LLC, v. 585, n. 7825, p. 357–362, set. 2020. Disponível em: [⟨https://doi.org/10.1038/s41586-020-2649-2⟩](https://doi.org/10.1038/s41586-020-2649-2).

HINTON, G. *rmsprop: Divide the gradient by a running average of its recent magnitude*. 2012. 26–31 p. Disponível em: [⟨https://www.cs.toronto.edu/~tijmen/csc321/slides/lecture_slides_lec6.pdf⟩](https://www.cs.toronto.edu/~tijmen/csc321/slides/lecture_slides_lec6.pdf).

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Comput.*, MIT Press, Cambridge, MA, USA, v. 9, n. 8, p. 1735–1780, nov. 1997. ISSN 0899-7667. Disponível em: [⟨https://doi.org/10.1162/neco.1997.9.8.1735⟩](https://doi.org/10.1162/neco.1997.9.8.1735).

- HUGGING FACE, INC. *Hugging Face*. 2025. <https://huggingface.co/>. Acessado em: 16/11/2025.
- JIANG, A. Q. *et al.* *Mistral 7B*. 2023. Disponível em: <https://arxiv.org/abs/2310.06825>.
- KIM, T. *python-dotenv*. 2025. <https://pypi.org/project/emoji/>. Acessado em 16/11/2025.
- KINGMA, D. P.; BA, J. *Adam: A Method for Stochastic Optimization*. 2017. Disponível em: <https://arxiv.org/abs/1412.6980>.
- KUMAR, S. *python-dotenv*. 2025. <https://pypi.org/project/python-dotenv/>. Acessado em 16/11/2025.
- LAZER, D. *et al.* The science of fake news. *Science*, v. 359, p. 1094–1096, 03 2018.
- LHOEST, Q. *et al.* Datasets: A community library for research on efficient data processing and loading. In: *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021. p. 1–7. Disponível em: <https://aclanthology.org/2021.emnlp-demos.1/>.
- MARTINS, A. D. F. *et al.* Covid19.br: A dataset of misinformation about covid-19 in brazilian portuguese whatsapp messages. In: SBC. *Anais do III Dataset Showcase Workshop*. [S.l.], 2021. p. 138–147.
- MCCARTHY, J. *et al.* What is artificial intelligence. Stanford University, 2007.
- MCKINNEY Wes. Data Structures for Statistical Computing in Python. In: WALT Stéfan van der; MILLMAN Jarrod (Ed.). *Proceedings of the 9th Python in Science Conference*. [S.l.: s.n.], 2010. p. 56 – 61.
- META. *Como o Facebook está lidando com as notícias falsas por meio de verificadores de fatos independentes?* 2025. <https://www.facebook.com/help/1952307158131536>. Central de Ajuda do Facebook.
- MONTEIRO, R. A. *et al.* Contributions to the study of fake news in portuguese: New corpus and automatic detection results. In: *Computational Processing of the Portuguese Language: 13th International Conference, PROPOR 2018, Canela, Brazil, September 24–26, 2018, Proceedings*. [S.l.]: Springer, 2018. v. 13, p. 324–334.
- MORENO, J. a.; BRESSAN, G. Factck.br: A new dataset to study fake news. In: *PROCEEDINGS of the 25th Brazilian Symposium on Multimedia and the Web*. [S.l.: s.n.], 2019. p. 525–527.
- NIELSEN, D. S.; MCCONVILLE, R. Mumin: A large-scale multilingual multimodal fact-checked misinformation social network dataset. In: *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*. New York, NY, USA: Association for Computing Machinery, 2022. (SIGIR '22), p. 3141–3153. ISBN 9781450387323. Disponível em: <https://doi.org/10.1145/3477495.3531744>.

OPENAI. *GPT-3.5-Turbo*. 2025. [⟨https://www.openai.com⟩](https://www.openai.com). LLM acessado via OpenAI API.

OPENAI. *GPT-4*. 2025. [⟨https://www.openai.com⟩](https://www.openai.com). LLM acessado via OpenAI API.

OPENAI. *GPT-5*. 2025. [⟨https://www.openai.com⟩](https://www.openai.com). LLM acessado via OpenAI API.

OPENAI. *GPT-5 nano*. 2025. [⟨https://www.openai.com⟩](https://www.openai.com). LLM acessado via OpenAI API.

OPENAI. *OpenAI Platform*. 2025. [⟨https://platform.openai.com/⟩](https://platform.openai.com/). Acessado em 16/11/2025.

OPENAI. *OpenAI Python API library*. 2025. [⟨https://github.com/openai/openai-python/⟩](https://github.com/openai/openai-python/). Acessado em 16/11/2025.

OPENAI. *Reasoning models*. 2025. [⟨https://platform.openai.com/docs/guides/reasoning⟩](https://platform.openai.com/docs/guides/reasoning). Documentação sobre Reasoning models da OpenAI Platform.

PASZKE, A. *et al.* *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. 2019. Disponível em: [⟨https://arxiv.org/abs/1912.01703⟩](https://arxiv.org/abs/1912.01703).

PEDREGOSA, F. *et al.* Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

PÉREZ, F.; GRANGER, B. E. IPython: a system for interactive scientific computing. *Computing in Science and Engineering*, IEEE Computer Society, v. 9, n. 3, p. 21–29, maio 2007. ISSN 1521-9615. Disponível em: [⟨https://ipython.org⟩](https://ipython.org).

PIAU, M.; LOTUFO, R.; NOGUEIRA, R. *ptt5-v2: A Closer Look at Continued Pretraining of T5 Models for the Portuguese Language*. 2024. Disponível em: [⟨https://arxiv.org/abs/2406.10806⟩](https://arxiv.org/abs/2406.10806).

POSETTI, J.; MATTHEWS, A. *A short guide to the history of 'fake news' and disinformation: A learning module for journalists and journalism educators*. Oxford: ICFJ, 2018. Commissioning Editor: Cherilyn Ireton; Published under Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0). Disponível em: [⟨https://www.icfj.org/sites/default/files/2018-07/A%20Short%20Guide%20to%20History%20of%20Fake%20News%20and%20Disinformation_ICFJ%20Final.pdf⟩](https://www.icfj.org/sites/default/files/2018-07/A%20Short%20Guide%20to%20History%20of%20Fake%20News%20and%20Disinformation_ICFJ%20Final.pdf).

POYNTER. *International Fact-Checking Network (IFCN)*. 2025. [⟨https://www.poynter.org/ifcn/⟩](https://www.poynter.org/ifcn/). Empowering fact-checkers worldwide.

PRINCE, S. J. *Understanding Deep Learning*. The MIT Press, 2023. Disponível em: [⟨http://udlbook.com⟩](http://udlbook.com).

SETTY, V. Surprising efficacy of fine-tuned transformers for fact-checking over larger language models. 2024. Disponível em: [⟨https://arxiv.org/abs/2402.12147⟩](https://arxiv.org/abs/2402.12147).

SILVA, F. R. M. d. *et al.* Fakenewssetgen: A process to build datasets that support comparison among fake news detection methods. In: *Proceedings of the Brazilian Symposium on Multimedia and the Web*. [S.l.: s.n.], 2020. p. 241–248.

SUNDRIYAL, M.; CHAKRABORTY, T.; NAKOV, P. *From Chaos to Clarity: Claim Normalization to Empower Fact-Checking*. 2024. Disponível em: <https://arxiv.org/abs/2310.14338>.

TIGRE, M. F. F. d. S. L. *Utilizando modelos de Machine Learning para classificar fake news de COVID-19*. Dissertação (Dissertação (Mestrado em Ciência da Computação)) — Universidade Federal de Pernambuco, Recife, 2023.

VASWANI, A. *et al.* Attention is all you need. In: *Proceedings of the 31st International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., 2017. (NIPS'17), p. 6000–6010. ISBN 9781510860964.

WERRA, L. V. *et al.* Evaluate & evaluation on the hub: Better best practices for data and model measurements. In: CHE, W.; SHUTOVA, E. (Ed.). *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Abu Dhabi, UAE: Association for Computational Linguistics, 2022. p. 128–136. Disponível em: <https://aclanthology.org/2022.emnlp-demos.13/>.

WOLF, T. *et al.* Huggingface's transformers: State-of-the-art natural language processing. *CoRR*, abs/1910.03771, 2019. Disponível em: <http://arxiv.org/abs/1910.03771>.

APÊNDICE A - Lista de ilustrações

Figura 1 – Exemplo de uma rede neural simples retirado do livro <i>Understanding Deep Learning</i> (PRINCE, 2023), no qual: o nó x representa a entrada do modelo; os nós h_1 , h_2 e h_3 correspondem aos neurônios da camada oculta, responsáveis por transformar a entrada por meio de combinações lineares e funções de ativação; o nó y representa a saída da rede, que agrega as informações provenientes da camada oculta; e as setas indicam as conexões direcionadas entre os neurônios, associadas aos pesos aprendidos durante o treinamento, definindo o fluxo de informação da entrada para a saída.	13
Figura 2 – Diagrama de arquitetura dos componentes do experimento.	20

APÊNDICE B - Lista de tabelas

Tabela 1	– Exemplos de publicações e suas afirmações extraídas retirados dos conjuntos de dados original e transformados baseados na base FakeTweet.Br (CORDEIRO; PINHEIRO, 2019).	9
Tabela 2	– Exemplos de publicações e suas afirmações normalizadas retirados do artigo “ <i>From Chaos to Clarity: Claim Normalization to Empower Fact-Checking</i> ” (SUNDRIYAL; CHAKRABORTY; NAKOV, 2024).	10
Tabela 3	– Bases de dados no âmbito de notícias falsas em português selecionadas para a condução dos experimentos desta pesquisa.	21
Tabela 4	– Métricas dos conjuntos de dados baseados no FakeTweet.Br.	34
Tabela 5	– Métricas dos conjuntos de dados baseados no Fake.Br.	35
Tabela 6	– Médias das métricas dos melhores modelos de cada um dos três ajustes-finos do <i>Transformer</i> XLM-RoBERTa-Large na classificação do conjunto de testes de todas as variações do conjunto de dados FakeTweet.Br.	38
Tabela 7	– Médias das métricas dos melhores modelos de cada um dos três ajustes-finos do <i>Transformer</i> XLM-RoBERTa-Large na classificação do conjunto de testes de todas as variações do conjunto de dados Fake.Br.	38
Tabela 8	– Médias das métricas dos melhores modelos de cada um dos três ajustes-finos do <i>Transformer</i> BERTimbau na classificação do conjunto de testes de todas as variações do conjunto de dados FakeTweet.Br.	38
Tabela 9	– Médias das métricas dos melhores modelos de cada um dos três ajustes-finos do <i>Transformer</i> BERTimbau na classificação do conjunto de testes de todas as variações do conjunto de dados Fake.Br.	39
Tabela 10	– Contagem de casos de melhora e piora na classificação das entradas do conjunto de dados FakeTweet.Br após os ajustes-finos do <i>Transformer</i> XLM-RoBERTa-Large com as versões da base resultantes das execuções das tarefas de extração e normalização de afirmações sobre a versão original.	40
Tabela 11	– Contagem de casos de melhora e piora na classificação das entradas do conjunto de dados Fake.Br após os ajustes-finos do <i>Transformer</i> XLM-RoBERTa-Large com as versões da base resultantes das execuções das tarefas de extração e normalização de afirmações sobre a versão original.	41

Tabela 12 – Contagem de casos de melhora e piora na classificação das entradas do conjunto de dados FakeTweet.Br após os ajustes-finos do <i>Transformer</i> BERTimbau com as versões da base resultantes das execuções das tarefas de extração e normalização de afirmações sobre a versão original.	41
Tabela 13 – Contagem de casos de melhora e piora na classificação das entradas do conjunto de dados Fake.Br após os ajustes finos do <i>Transformer</i> BERTimbau com as versões da base resultantes das execuções das tarefas de extração e normalização de afirmações sobre a versão original.	41
Tabela 14 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> XLM-RoBERTa-Large na classificação do conjunto de testes da base FakeTweet.BR Original.	61
Tabela 15 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> XLM-RoBERTa-Large na classificação do conjunto de testes da base FakeTweet.BR <i>Claim Extraction</i> (GPT-5 nano).	61
Tabela 16 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> XLM-RoBERTa-Large na classificação do conjunto de testes da base FakeTweet.BR <i>Claim Extraction</i> (GPT-5).	62
Tabela 17 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> XLM-RoBERTa-Large na classificação do conjunto de testes da base FakeTweet.BR <i>Claim Normalization</i> (GPT-5 nano).	62
Tabela 18 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> XLM-RoBERTa-Large na classificação do conjunto de testes da base FakeTweet.BR <i>Claim Normalization</i> (GPT-5).	62
Tabela 19 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> XLM-RoBERTa-Large na classificação do conjunto de testes da base Fake.br Original.	63
Tabela 20 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> XLM-RoBERTa-Large na classificação do conjunto de testes da base Fake.br <i>Claim Extraction</i> (GPT-5 nano).	63
Tabela 21 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> XLM-RoBERTa-Large na classificação do conjunto de testes da base Fake.br <i>Claim Normalization</i> (GPT-5 nano).	63
Tabela 22 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> BERTimbau na classificação do conjunto de testes da base FakeTweet.BR Original.	64
Tabela 23 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> BERTimbau na classificação do conjunto de testes da base FakeTweet.BR <i>Claim Extraction</i> (GPT-5 nano).	64

Tabela 24 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> BERTimbau na classificação do conjunto de testes da base FakeTweet.BR <i>Claim Extraction</i> (GPT-5).	64
Tabela 25 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> BERTimbau na classificação do conjunto de testes da base FakeTweet.BR <i>Claim Normalization</i> (GPT-5 nano).	65
Tabela 26 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> BERTimbau na classificação do conjunto de testes da base FakeTweet.BR <i>Claim Normalization</i> (GPT-5).	65
Tabela 27 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> BERTimbau na classificação do conjunto de testes da base Fake.br Original.	65
Tabela 28 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> BERTimbau na classificação do conjunto de testes da base Fake.br <i>Claim Extraction</i> (GPT-5 nano).	66
Tabela 29 – Métricas dos melhores modelos de cada ajuste-fino do <i>Transformer</i> BERTimbau na classificação do conjunto de testes da base Fake.br <i>Claim Normalization</i> (GPT-5 nano).	66

APÊNDICE C – Bibliotecas Python utilizadas na construção dos Jupyter Notebooks do experimento

Para implementação dos componentes do experimento, sem contar com as bibliotecas nativas do Python como “*json*”, “*os*” e “*logging*”, foram utilizadas as seguintes bibliotecas de terceiros:

- ***dotenv***: permite carregar variáveis de ambiente a partir de um arquivo *.env* para configuração segura de aplicações.. (KUMAR, 2025).
- ***pandas***: biblioteca para manipulação e análise de dados usando a estrutura de dados *DataFrame*. (MCKINNEY, 2010).
- ***numpy***: pacote para computação numérica eficiente com suporte a *arrays* multidimensionais. (HARRIS *et al.*, 2020).
- ***openai***: cliente oficial para acessar APIs da OpenAI em aplicações Python. (OPENAI, 2025f).
- ***pytorch***: *framework* de *deep learning* que fornece suporte para realizações de operações tensoriais e construção dinâmica de modelos neurais. (PASZKE *et al.*, 2019).
- ***sklearn***: biblioteca de aprendizado de máquina com algoritmos de aprendizado supervisionado e não supervisionado. (PEDREGOSA *et al.*, 2011).
- ***evaluate***: ferramenta da Hugging Face (HUGGING FACE, INC., 2025) para calcular métricas padronizadas de avaliação em modelos de ML. (WERRA *et al.*, 2022).
- ***tdm***: biblioteca para criar barras de progresso customizáveis em laços de repetição. (COSTA-LUIS, 2019).
- ***emoji***: pacote para manipular, converter e renderizar *emojis* em strings Python. Nesta pesquisa, é usada para remover *emojis* que possam estar inseridos no meio de entradas dos conjuntos de dados. (KIM, 2025).
- ***datasets***: biblioteca da Hugging Face (HUGGING FACE, INC., 2025) para carregar, processar e compartilhar grandes conjuntos de dados. (LHOEST *et al.*, 2021).

- ***transformers***: biblioteca da Hugging Face (HUGGING FACE, INC., 2025) para uso e treinamento de modelos baseados em , como BERTimbau e XLM-RoBERTa-Large usados por esta pesquisa. (WOLF *et al.*, 2019).

APÊNDICE D – Configurações dos LLMs e das Tarefas no Componente Responsável pela Transformação de Conjuntos de Dados

As configurações do componente responsável pela transformação de conjuntos de dados a partir das tarefas de extração e normalização de afirmações relativas aos LLMs e as tarefas são:

- **MODEL:** qual será o LLM utilizado para o processamento das tarefas (no escopo desta pesquisa, GPT-5 nano e GPT-5);
- **TASKS:** quais tarefas devem ser executadas sobre o conjunto (extração de afirmações, normalização de afirmações ou ambas);
- **TEMPERATURE:** parâmetro que controla o nível de aleatoriedade das respostas geradas por um modelo. Para os modelos da OpenAI utilizados nesta pesquisa, a temperatura varia de 0 a 2. O valor padrão para as execuções dos experimentos foi 1;

Observação: o modelo GPT-5 nano não suporta a temperatura 0.

- **VERBOSITY:** define o nível de detalhamento e extensão das respostas produzidas pelo modelo. Para os modelos da OpenAI utilizados nesta pesquisa, a verbosidade pode ser definida como “low”, “medium” ou “high”. O valor padrão para as execuções dos experimentos foi “low”;
- **REASONING_EFFORT:** define o nível de profundidade do raciocínio que o modelo terá antes de responder. Para os modelos da OpenAI utilizados nesta pesquisa, o esforço do raciocínio pode ser definida como “low”, “medium” ou “high”. O valor padrão para as execuções dos experimentos foi “high” por favorecer a cadeia de pensamentos do modelo, benéfico para a normalização (SUNDRIYAL; CHAKRABORTY; NAKOV, 2024);
- **ROWS_PER_BATCH:** define a quantidade de entradas por lote que serão processadas pela API da OpenAI. O valor padrão para as execuções dos experimentos foi 5000;

Observação: o tamanho do lote é baseado em quantas linhas do conjunto de dados original serão utilizadas para a montagem dos lotes. Se o componente estiver configurado para gerar os conjuntos de dados para as tarefas de extração

e normalização de afirmações em paralelo, isso implicará em duas requisições por entrada da base original (uma por tarefa), totalizando duas vezes o número definido. No caso do valor padrão de 5,000 linhas do conjunto de dados original por lote, 10,000 requisições serão feitas para a API da OpenAI.

APÊNDICE E – Configurações dos ajustes-finos dos *Transformers*

Os argumentos e parâmetros utilizados pelo experimento nos ajustes-finos dos *Transformers* são:

- ***learning_rate***: taxa de aprendizado inicial. Define o tamanho das atualizações nos pesos do modelo. O valor escolhido foi de 2×10^{-5} , que é um valor razoável e padrão sugerido pela biblioteca;
- ***lr_scheduler_type***: define como a taxa de aprendizado varia ao longo do treino. Neste caso, o comportamento de decaimento definido para a taxa de aprendizado foi linear;
- ***warmup_ratio***: a razão que representará a quantidade de passos de aquecimento durante o treino. O aquecimento serve para evitar explosões de gradientes no começo dos treinamentos e consiste basicamente na subida da taxa de aprendizagem de 0 até o valor inicial definido pelo parâmetro *learning_rate* de maneira gradual. Para este experimento, a razão escolhida foi de 0.1, ou seja, os primeiros 10% dos passos do treinamento serão de aquecimento;
- ***per_device_train_batch_size***: Quantidade de entradas por lote por GPU/CPU durante o **treinamento**. Após alguns testes, foi escolhido o tamanho de 24 entradas por lote, pois foi o tamanho que mais possibilitou aproveitar os 16 GBs de VRAM disponibilizados pela GPU da máquina que executou os ajustes-finos sem haver muito compartilhamento de memória com a RAM do sistema;
- ***per_device_eval_batch_size***: Quantidade de entradas por lote por GPU/CPU durante o **teste**. Após alguns testes, foi escolhido o tamanho de 24 entradas por lote, pois foi o tamanho que mais possibilitou aproveitar os 16 GBs de VRAM disponibilizados pela GPU da máquina que executou os ajustes-finos sem haver muito compartilhamento de memória com a RAM do sistema;
- ***num_train_epochs***: número de épocas completas sobre o conjunto de dados. Neste caso, foi definido o treinamento por dez épocas, com possível parada precoce caso o modelo não melhore em um determinado número de épocas;
- ***weight_decay***: regularização L2 dos pesos do modelo aplicada durante o treinamento com o intuito de reduzir *overfitting*;

- ***do_eval***: ativa a fase de avaliação do modelo durante o treino. No caso do experimento, a avaliação do modelo é habilitada;
- ***eval_strategy***: controla quando a avaliação do modelo acontece. Para este experimento, foi definido que a avaliação acontece sempre ao final de cada época;
- ***metric_for_best_model***: métrica que será denominada como principal responsável por definir qual é o melhor modelo resultante do treinamento. No caso do experimento, a métrica “*eval_loss*”, ou perda durante a avaliação do modelo, foi selecionada por representar o resultado da aplicação do que o modelo aprendeu no conjunto de testes;
- ***load_best_model_at_end***: variável de controle para saber se o treinador do modelo deve ou não carregar o melhor modelo resultante do ajuste-fino ao final do treinamento ou não. Como mais adiante o componente utiliza o melhor modelo do treinamento para fazer classificações, o valor deste parâmetro para este experimento é verdadeiro;
- ***fp16***: aciona o treinamento em meia precisão, que é uma técnica da NVIDIA para aceleração do treinamento e redução do uso de VRAM. Como a GPU utilizada para a execução do experimento suporta a precisão “*bf16*” (explicada abaixo) e não é recomendado o uso concomitante das duas configurações, o valor deste parâmetro para este experimento é falso;
- ***bf16***: semelhante ao “*fp16*”, porém usa uma estratégia de *mixed precision*, muito mais eficiente e estável para GPUs da arquitetura da que o experimento utilizou. Por conta disso, o valor deste parâmetro para este experimento é verdadeiro.

APÊNDICE F – Resultados dos ajustes-finos dos *Transformers*

O propósito deste apêndice é expor todos os valores das métricas obtidas em todos os 48 treinamentos de ajuste-fino dos *Transformers* durante o experimento. Estes são os valores utilizados para calcular as médias mostradas nas tabelas da Seção 5.

XLM-RoBERTa-Large — FakeTweet.BR — Original				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,434	0,236	0,283	0,318
Acurácia	0,778	0,911	0,889	0,859
Precisão	0,767	0,939	0,938	0,881
Recall	1,000	0,939	0,909	0,949
F1	0,868	0,939	0,923	0,910

Tabela 14 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* XLM-RoBERTa-Large na classificação do conjunto de testes da base FakeTweet.BR Original.

XLM-RoBERTa-Large — FakeTweet.BR — <i>Claim Extraction</i> (GPT-5 nano)				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,257	0,439	0,375	0,357
Acurácia	0,844	0,844	0,889	0,859
Precisão	0,906	0,882	0,868	0,886
Recall	0,879	0,909	1,000	0,929
F1	0,892	0,896	0,930	0,906

Tabela 15 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* XLM-RoBERTa-Large na classificação do conjunto de testes da base FakeTweet.BR *Claim Extraction* (GPT-5 nano).

XLM-RoBERTa-Large — FakeTweet.BR — <i>Claim Extraction</i> (GPT-5)				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,330	0,600	0,571	0,500
Acurácia	0,867	0,733	0,733	0,778
Precisão	0,966	0,733	0,733	0,811
Recall	0,848	1,000	1,000	0,949
F1	0,903	0,846	0,846	0,865

Tabela 16 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* XLM-RoBERTa-Large na classificação do conjunto de testes da base FakeTweet.BR *Claim Extraction* (GPT-5).

XLM-RoBERTa-Large — FakeTweet.BR — <i>Claim Normalization</i> (GPT-5 nano)				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,309	0,353	0,336	0,333
Acurácia	0,911	0,911	0,867	0,896
Precisão	0,892	0,939	0,886	0,906
Recall	1,000	0,939	0,939	0,960
F1	0,943	0,939	0,912	0,931

Tabela 17 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* XLM-RoBERTa-Large na classificação do conjunto de testes da base FakeTweet.BR *Claim Normalization* (GPT-5 nano).

XLM-RoBERTa-Large — FakeTweet.BR — <i>Claim Normalization</i> (GPT-5)				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,381	0,378	0,508	0,423
Acurácia	0,844	0,844	0,733	0,807
Precisão	0,861	0,842	0,733	0,812
Recall	0,939	0,970	1,000	0,970
F1	0,899	0,901	0,846	0,882

Tabela 18 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* XLM-RoBERTa-Large na classificação do conjunto de testes da base FakeTweet.BR *Claim Normalization* (GPT-5).

XLM-RoBERTa-Large — Fake.br — Original				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,121	0,123	0,235	0,160
Acurácia	0,969	0,960	0,937	0,955
Precisão	0,973	0,957	0,931	0,954
Recall	0,968	0,965	0,949	0,961
F1	0,970	0,961	0,940	0,957

Tabela 19 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* XLM-RoBERTa-Large na classificação do conjunto de testes da base Fake.br Original.

XLM-RoBERTa-Large — Fake.br — <i>Claim Extraction</i> (GPT-5 nano)				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,681	0,541	0,633	0,618
Acurácia	0,488	0,769	0,652	0,637
Precisão	0,523	0,814	0,726	0,688
Recall	0,121	0,718	0,527	0,455
F1	0,197	0,763	0,611	0,523

Tabela 20 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* XLM-RoBERTa-Large na classificação do conjunto de testes da base Fake.br *Claim Extraction* (GPT-5 nano).

XLM-RoBERTa-Large — Fake.br — <i>Claim Normalization</i> (GPT-5 nano)				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,429	0,445	0,525	0,467
Acurácia	0,823	0,815	0,809	0,816
Precisão	0,851	0,872	0,807	0,843
Recall	0,798	0,753	0,831	0,794
F1	0,824	0,808	0,819	0,817

Tabela 21 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* XLM-RoBERTa-Large na classificação do conjunto de testes da base Fake.br *Claim Normalization* (GPT-5 nano).

BERTimbau — FakeTweet.BR — Original				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,209	0,143	0,220	0,191
Acurácia	0,889	0,978	0,933	0,933
Precisão	0,868	0,971	0,941	0,927
Recall	1,000	1,000	0,970	0,990
F1	0,930	0,985	0,955	0,957

Tabela 22 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* BERTimbau na classificação do conjunto de testes da base FakeTweet.BR Original.

BERTimbau — FakeTweet.BR — <i>Claim Extraction</i> (GPT-5 nano)				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,224	0,375	0,364	0,321
Acurácia	0,933	0,867	0,844	0,881
Precisão	0,941	0,846	0,842	0,876
Recall	0,970	1,000	0,970	0,980
F1	0,955	0,917	0,901	0,924

Tabela 23 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* BERTimbau na classificação do conjunto de testes da base FakeTweet.BR *Claim Extraction* (GPT-5 nano).

BERTimbau — FakeTweet.BR — <i>Claim Extraction</i> (GPT-5)				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,351	0,304	0,341	0,332
Acurácia	0,822	0,889	0,911	0,874
Precisão	0,903	0,912	0,914	0,910
Recall	0,848	0,939	0,970	0,919
F1	0,875	0,925	0,941	0,914

Tabela 24 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* BERTimbau na classificação do conjunto de testes da base FakeTweet.BR *Claim Extraction* (GPT-5).

BERTimbau — FakeTweet.BR — <i>Claim Normalization</i> (GPT-5 nano)				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,354	0,344	0,328	0,342
Acurácia	0,889	0,889	0,867	0,881
Precisão	0,889	0,868	0,865	0,874
Recall	0,970	1,000	0,970	0,980
F1	0,928	0,930	0,914	0,924

Tabela 25 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* BERTimbau na classificação do conjunto de testes da base FakeTweet.BR *Claim Normalization* (GPT-5 nano).

BERTimbau — FakeTweet.BR — <i>Claim Normalization</i> (GPT-5)				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,293	0,325	0,252	0,290
Acurácia	0,889	0,822	0,911	0,874
Precisão	0,938	0,857	0,892	0,896
Recall	0,909	0,909	1,000	0,939
F1	0,923	0,882	0,943	0,916

Tabela 26 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* BERTimbau na classificação do conjunto de testes da base FakeTweet.BR *Claim Normalization* (GPT-5).

BERTimbau — Fake.br — Original				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,101	0,138	0,123	0,121
Acurácia	0,978	0,958	0,972	0,969
Precisão	0,986	0,945	0,973	0,968
Recall	0,970	0,976	0,973	0,973
F1	0,978	0,960	0,973	0,971

Tabela 27 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* BERTimbau na classificação do conjunto de testes da base Fake.br Original.

BERTimbau — Fake.br — <i>Claim Extraction</i> (GPT-5 nano)				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,509	0,469	0,485	0,488
Acurácia	0,757	0,768	0,759	0,761
Precisão	0,811	0,769	0,760	0,780
Recall	0,691	0,788	0,782	0,754
F1	0,746	0,778	0,771	0,765

Tabela 28 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* BERTimbau na classificação do conjunto de testes da base Fake.br *Claim Extraction* (GPT-5 nano).

BERTimbau — Fake.br — <i>Claim Normalization</i> (GPT-5 nano)				
Métrica	Treino 1	Treino 2	Treino 3	Média
Perda	0,410	0,447	0,394	0,417
Acurácia	0,825	0,807	0,825	0,819
Precisão	0,834	0,903	0,842	0,860
Recall	0,825	0,702	0,815	0,780
F1	0,830	0,790	0,828	0,816

Tabela 29 – Métricas dos melhores modelos de cada ajuste-fino do *Transformer* BERTimbau na classificação do conjunto de testes da base Fake.br *Claim Normalization* (GPT-5 nano).

Agradecimentos

Nesta seção, quero agradecer a todas as pessoas que possibilitaram a finalização deste trabalho. Não é possível fazer nada sozinho na vida, e este trabalho não foi diferente.

Antes de tudo, agradeço à minha mãe Núbia. Responsável direta por todo e qualquer sucesso que eu já tive e possa ter nessa vida. A pessoa com quem eu sei que sempre posso contar e que nunca soltou e nem vai soltar minha mão. Poderia escrever outro artigo e com infinitas páginas sobre o quanto te amo, o quanto te admiro e o quanto tenho você como referência na minha vida, mas ainda sim faltariam palavras. Sou eternamente grato por nascer seu filho e lhe agradeço pela ajuda providencial para mais essa conquista na minha vida.

Agradeço à minha namorada Rebeca. Sem ela, nada disso seria possível. Agradeço todos os dias por sua vida e por você me conceder a benção que é poder partilhá-la com você. Acordar do seu lado todos os dias é muito além do que eu jamais imaginei e sonhei de bom para a minha vida. Obrigado pelo apoio.

Agradeço à minha irmã Julie. Minha irmã que sempre cuidou de mim, desde pequeno até hoje. Que não mede esforços para me ver bem. A quem eu daria a minha vida se fosse preciso, e que tenho certeza que daria a vida por mim também. Quero que saiba que tenho muito orgulho de te chamar de irmã, que te amo muito e que, mesmo às vezes estando longe, estou sempre aqui para você também.

Agradeço ao meu pai Ricardo. Meu primeiro e melhor amigo. Que me apresentou a música e inúmeras das outras coisas que mais gosto nessa vida. Quero que você saiba que estou sempre aqui para você, assim como sei que você está aqui para mim também, não importa a distância entre nós.

Agradeço à minha psicóloga Thalita. Agradeço pela dedicação, cuidado e paciência incondicionais durante nossas sessões. Também agradeço pelas ferramentas que você me mostrou e ensinou a usar para navegar nesta vida de uma maneira mais leve e saudável. Obrigado por me ajudar a me conhecer e a desenvolver as estratégias que foram cruciais para o triunfo sobre os desafios destes últimos anos de faculdade.

Agradeço à minha professora orientadora Aline. Agradeço pela paciência e gentileza de ter me guiado por este trabalho desde o seu começo até sua conclusão e espero que possamos trabalhar juntos novamente. Agradeço também ao meu coorientador Vítor, que também se dedicou e cedeu seu tempo para me ajudar a desenvolver e concluir este trabalho.

Agradeço à Universidade Federal Fluminense. Agradeço pelos excelentes pro-

fessores e pela estrutura que me foi dada para a conclusão da minha graduação.

E por fim, mas não menos importante, agradeço aos meus gatinhos Milk e Thales, que nos deixaram durante a escrita deste artigo, mas que continuam cuidando de nós de onde quer que estejam. Amo vocês eternamente.

A conclusão deste trabalho representa uma enorme conquista na minha vida para mim, e ela não teria sido possível sem a ajuda de vocês. Essa conquista é de todos que foram mencionados aqui e de todos os que não foram, mas são importantes na minha vida. Essa conquista é nossa!

Muito obrigado.